Universitat de les Illes Balears

TRABAJO DE FIN DE GRADO

# ANÁLISIS DE CLUSTERING PARA LA IDENTIFICACIÓN DE SUSTITUTOS EN FÚTBOL PROFESIONAL: EL CASO DE ANTONIO RAÍLLO

**Joan Miquel Rubí Garcías**

Matemàtiques

**Escola Politècnica Superior**

**Any acadèmic 2025-26**

# ANÁLISIS DE CLUSTERING PARA LA IDENTIFICACIÓN DE SUSTITUTOS EN FÚTBOL PROFESIONAL: EL CASO DE ANTONIO RAÍLLO

**Joan Miquel Rubí Garcías**

**Trabajo de Fin de Grado**

**Escola Politècnica Superior**

**Universitat de les Illes Balears**

**Any acadèmic 2025-26**

Paraules clau del treball: clustering, análisis de datos, fútbol, sustitución de jugadores, ACP

*Tutor: PhD Nelson Alirio Cruz Gutiérrez*

# Índice general

**Índice general** **i**

**Resumen** **iii**

**1 Introducción** **5**

**2 Datos** **9**
2.1 Fuentes y alcance . . . . . 9
2.2 Extracción y construcción . . . . . 10
2.3 Limpieza y depuración . . . . . 10
2.4 Narrativa aplicada: insertar a Raíllo en el espacio de datos . . . . . 11
2.5 Descripción exploratoria . . . . . 11
2.5.1 Variables Cualitativas . . . . . 11
2.5.2 Variables Cuantitativas . . . . . 13

**3 Metodología de análisis** **17**
3.1 Distancias, estandarización y motivación geométrica . . . . . 17
3.2 Clustering jerárquico y particional . . . . . 17
3.2.1 Clustering jerárquico . . . . . 17
3.3 Clustering particional (*K-Means* y *K-Medoids*) . . . . . 24
3.3.1 *K-Means* . . . . . 24
3.3.2 *K-Medoids* . . . . . 25
3.3.3 Algoritmo de Hartigan y Wong . . . . . 25
3.4 Índices de validación y comparación de particiones . . . . . 26
3.4.1 Índice *Silhouette* . . . . . 26
3.4.2 Estadístico *Gap* . . . . . 27
3.4.3 Índice de Rand . . . . . 27

**4 Resultados** **29**
4.1 Clustering en el conjunto completo . . . . . 29
4.1.1 Índice de Silueta . . . . . 29
4.1.2 Índice de Calinski–Harabasz . . . . . 30
4.2 ACP y clustering en espacio reducido . . . . . 30
4.2.1 Índice de Silueta . . . . . 32
4.2.2 Índice de Calinski–Harabasz . . . . . 32
4.3 Clustering con restricción posicional a DFC y posiciones cercanas . . . 33
4.3.1 Índice de Silueta . . . . . 33

4.3.2 Índice de Calinski–Harabasz . . . . . 33
4.4 ACP en el subconjunto posicional y clustering . . . . . 34
4.4.1 Índice de Silueta . . . . . 35
4.4.2 Índice de Calinski–Harabasz . . . . . 36
4.5 Candidatos a sustitutos . . . . . 36
4.5.1 Ranking con la base de datos completa . . . . . 37
4.5.2 Ranking restringido a posiciones cercanas a DFC . . . . . 37
4.5.3 Síntesis de candidatos recurrentes . . . . . 37
4.5.4 Sustitutos condicionados . . . . . 38

**5 Simulación y candidatos elegidos 41**
5.1 Elección de sustituto . . . . . 47

**6 Discusión y conclusiones 49**
6.1 Líneas futuras . . . . . 50

**Bibliografía 51**

# Resumen

El presente trabajo analiza la aplicación de técnicas de análisis de datos para la identificación de posibles sustitutos en el fútbol profesional, tomando como caso de estudio al jugador Antonio Raíllo. La creciente necesidad de los clubes de reemplazar futbolistas por motivos como traspasos, lesiones o retirada deportiva hace imprescindible el uso de herramientas objetivas que apoyen la toma de decisiones.

El objetivo principal es obtener una lista de candidatos que presenten similitudes con el jugador de referencia a partir de datos de rendimiento. Para ello, se emplean datos extraídos de FBref correspondientes a las cinco grandes ligas europeas durante la temporada 2024/2025. La metodología adoptada es de carácter exploratorio y combina técnicas de clustering jerárquico y K-means con Análisis de Componentes Principales (ACP), implementadas en R. Asimismo, se realiza un proceso de recopilación de datos mediante web scraping utilizando Python.

Los resultados muestran la existencia de perfiles con características similares al jugador analizado, destacando especialmente la recurrencia de ciertos candidatos en distintos escenarios. Entre ellos, Charlie Creswell aparece como el jugador más frecuente, mientras que César Tárrega presenta el mejor rendimiento en las simulaciones realizadas.

En conclusión, el uso combinado de técnicas de clustering y reducción de dimensionalidad permite identificar perfiles comparables de manera sistemática, aportando una herramienta útil en el ámbito del análisis deportivo. No obstante, el estudio presenta limitaciones relacionadas con el acceso restringido a datos internos de los clubes y con la dependencia de las variables seleccionadas y la métrica de distancia utilizada, lo que puede influir en los resultados obtenidos.

# Acrónimos

## Glosario y modelo del problema

### Estructura de los datos

**Matriz de datos:** Sea $\mathbf{X} = (x_{ij})$ una matriz de tamaño $n \times p$, donde $n$ es el número de observaciones (jugadores), $p$ es el número de variables (estadísticas) y $x_{ij}$ es el valor de la variable $j = 1, \ldots, p$ para la observación $i = 1, \ldots, n$.

**Vectores de observación y de variable:** $\mathbf{x}_i = (x_{i1}, \ldots, x_{ip})$ es el vector de características de la observación $i$; $\mathbf{x}_{\cdot j} = (x_{1j}, \ldots, x_{nj})$ es la columna asociada a la variable $j$.

**Medias:** $\bar{\mathbf{x}} = \frac{1}{n}\sum_{i=1}^{n} \mathbf{x}_i$ denota la media global del conjunto de datos.

## Clustering y notación asociada

**Partición en clústeres:** $C = \{C_1, \ldots, C_q\}$ es una partición del conjunto de observaciones en $q$ clústeres disjuntos cuya unión es el conjunto total. $n_k = |C_k|$ es el tamaño del clúster $k = 1, \ldots, q$.

**Asignación:** $C : \{1, \ldots, n\} \to \{1, \ldots, q\}$, tal que $C(i)$ denota el índice del clúster asignado a la observación $i$.

**Representantes del clúster:** $\mathbf{c}_k$ es un representante del clúster $k$; según el método puede ser un centroide (media) o un medoide (una observación del propio clúster).

$\bar{\mathbf{x}}_k = \frac{1}{n_k}\sum_{i:C(i)=k}^{n_k} \mathbf{x}_i$ denota el centroide del clúster $k$ calculado como la media de los puntos asignados a dicho clúster.

## Medidas de distancia y disimilitud

**Distancia euclídea:** $d(\mathbf{x}_i, \mathbf{x}_j) = \|\mathbf{x}_i - \mathbf{x}_j\| = \sqrt{\sum_{l=1}^{p} (x_{il} - x_{jl})^2}$.

**Distancia euclídea al cuadrado:** $d^2(\mathbf{x}_i, \mathbf{x}_j) = \sum_{l=1}^{p} (x_{il} - x_{jl})^2$.

**Matriz de covarianzas:** $\mathbf{S} = \frac{1}{n-1}(\mathbf{X} - \bar{\mathbf{X}})^\top (\mathbf{X} - \bar{\mathbf{X}})$.

**Descomposición espectral:** $\mathbf{S} = \mathbf{E}\Lambda\mathbf{E}^\top$, donde $\mathbf{E} = [\mathbf{e}_1, \ldots, \mathbf{e}_p]$ es la matriz de autovectores y $\Lambda = \mathrm{diag}(\lambda_1, \ldots, \lambda_p)$ contiene los autovalores ordenados no crecientemente.

## Acrónimos

| Siglas | Castellano | Original |
|---|---|---|
| FIFA | Federación Internacional de Fútbol Asociación | Fédération Internationale de Football Association |
| DFC | Defensa Central | Defensa Central |
| LD | Lateral Derecho | Lateral Derecho |
| LI | Lateral Izquierdo | Lateral Izquierdo |
| MCD | Mediocentro Defensivo | Mediocentro Defensivo |
| IFAB | Junta de la Asociación Internacional de Fútbol | International Football Association Board |
| RCD | Real Club Deportivo | Real Club Deportivo |
| ACP | Análisis de las Componentes Principales | Análisis de las Componentes Principales |

Tabla 0.1: Relación de acrónimos empleados en el estudio, incluyendo su denominación en español y su equivalente original.

## El fútbol como sistema de datos

En este trabajo se entiende el fútbol como un sistema en el que cada partido y cada acción generan información cuantificable. Dicha información puede organizarse en variables que describen distintos aspectos del rendimiento deportivo, tanto colectivos como individuales. El juego, en este contexto, se interpreta como una fuente estructurada de datos que permite caracterizar a los jugadores mediante medidas objetivas. Un jugador se representa matemáticamente como una observación del conjunto de datos, caracterizada por un conjunto de $p$ variables cuantitativas o cualitativas que describen su rendimiento, estilo o participación en el juego. Cada jugador se asocia a un vector de características en un espacio euclídeo de dimensión $p$.

## Representación vectorial

Sea $p$ el número de variables seleccionadas para describir el rendimiento individual. Cada jugador se representa mediante un vector $\mathbf{x}_i = (x_{i1}, x_{i2}, \ldots, x_{ip}) \in \mathbb{R}^p$, donde $x_{ij}$ es el valor de la variable $j$ para el jugador i. El conjunto de todos los jugadores constituye un subconjunto de $\mathbb{R}^p$ que puede analizarse mediante técnicas de reducción de dimensionalidad y métodos de agrupamiento.

## Modelo del fútbol y representación vectorial

En este trabajo, el fútbol se modeliza como un sistema generador de datos cuantificables derivados de las acciones de juego y del rendimiento de los jugadores. Bajo este enfoque, cada jugador puede representarse mediante un vector de características en un espacio euclídeo de dimensión $p$, lo que permite aplicar técnicas de análisis multivariante como medidas de distancia, reducción de dimensionalidad y métodos de agrupamiento.

El jugador de referencia considerado es Antonio Raíllo, cuyo vector se denota por $x_r \in \mathbb{R}^p$. A partir de esta representación, el objetivo consiste en identificar otros jugadores cuyos vectores $x_i \in \mathbb{R}^p$ resulten cercanos a $x_r$ según una función de distancia

$d(x_r, x_i)$, incorporando además restricciones asociadas a la posición en el campo y al año de nacimiento.

### GitHub

El código y los materiales utilizados en este trabajo están disponibles en:
`https://github.com/joanmiquelr/TFG-Clustering-Sustitutos-Futbol`

CAPÍTULO 1

# INTRODUCCIÓN

El fútbol es un deporte colectivo en el que compiten dos equipos formados por once jugadores cada uno (además de los correspondientes suplentes) con el objetivo de ganar el partido, lo cual se consigue marcando un número mayor de goles que el rival. Su origen moderno se sitúa en Inglaterra a mediados del siglo XIX; no obstante, sus bases institucionales quedaron consolidadas en 1904 con la fundación de la FIFA (Revista Líbero 2024).

El organismo encargado de regular las reglas del juego es la IFAB. Entre las normas fundamentales destaca la prohibición general de tocar el balón con las manos, permitiéndose únicamente al portero hacerlo y exclusivamente dentro del área, zona delimitada por líneas blancas próximas a la portería.

En España, en el año 2024 se registraron 1.260.556 licencias federativas activas de jugadores de fútbol (Consejo Superior de Deportes 2025), lo que representa aproximadamente un 30 % del total de licencias deportivas activas en dicho año. Este dato evidencia la relevancia social del fútbol en nuestro país y explica que sea considerado el “deporte rey”.

En el fútbol profesional existen dos ventanas de traspasos delimitadas por las respectivas ligas (cada una con un cierre fijado en una fecha y hora concretas, generalmente a las 23:59 de un día determinado), que en España se conocen como mercado de verano (julio-agosto) y mercado de invierno (enero). Estas ventanas permiten reforzar las plantillas antes o durante la temporada, sustituir jugadores por diversos motivos (lesiones, sanciones disciplinarias, entre otros) o traspasar jugadores con el fin de obtener un rédito económico. En España, dichos traspasos deben inscribirse dentro del límite temporal establecido en la sede de La Liga y cumplir con la normativa de la FIFA. En caso de que el club dispute competiciones europeas, podrá asimismo (aunque no es obligatorio (Marca 2025b)) inscribir al jugador en la lista de la UEFA. Si bien no es obligatorio registrar un fichaje en la competición nacional, carecería de sentido realizar una inversión económica sin formalizar su inscripción, especialmente teniendo en cuenta que en España la principal restricción es el máximo de 25 jugadores inscritos.

En la actualidad, aunque las plantillas cuentan con un límite de inscripción, es

posible ampliar el número de jugadores disponibles recurriendo al filial. Por este motivo, los clubes suelen disponer de plantillas compuestas por entre 25 y 30 jugadores. En LaLiga, la media es de 25,7 jugadores por club, según Transfermarkt (2026).

En los últimos años, diversos clubes han reconocido el uso del análisis de datos en los procesos de fichajes. Entre los ejemplos más destacados se encuentran el Unión Saint Gilloise y el Brighton & Hove Albion, entidades presididas por el matemático Tony Bloom, quien desarrolló un algoritmo orientado a la identificación de sustitutos y talento emergente. Un caso paradigmático es el de Moisés Caicedo (jugador ecuatoriano fichado por el Brighton por aproximadamente 4 millones de libras, más un porcentaje de una futura venta), posteriormente traspasado al Chelsea por 116 millones de libras, lo que evidencia la rentabilidad del sistema implementado y de la aplicación de herramientas matemáticas en la toma de decisiones deportivas.

Habitualmente, la figura encargada de la planificación y ejecución de estos fichajes es el Director Deportivo, en el caso del RCD Mallorca dicha responsabilidad recae en Pablo Ortells. No se trata de una tarea sencilla, especialmente en España, donde los controles económicos son de los más exigentes entre las cinco grandes ligas europeas. Esta circunstancia reduce el margen de error y obliga a maximizar la eficiencia en la toma de decisiones, ya que un fichaje fallido puede condicionar el rendimiento y la estabilidad económica del club durante varias temporadas.

La figura del Director Deportivo, junto con la del entrenador, suele ser una de las más cuestionadas en el entorno futbolístico, en parte debido a las filtraciones a la prensa (frecuentemente sesgadas) que rodean las decisiones deportivas. En este contexto, el presente trabajo tiene como objetivo desarrollar una herramienta que facilite la posible sustitución de uno de los referentes del RCD Mallorca, Antonio Raíllo (jugador de fútbol que habitualmente se desempeña en la posición de Defensa Central (DFC)), identificando perfiles estadísticamente similares al suyo.

Para la construcción de la metodología se han tenido en cuenta diversos trabajos previos en el ámbito del análisis de datos aplicado al deporte. En particular, la revisión sistemática de Gu et al. (2025) pone de manifiesto que, en la identificación de estilos de juego en fútbol, son frecuentes las técnicas de Análisis de Componentes Principales (ACP) y los algoritmos de clustering, siendo k-means uno de los más utilizados. En esta línea, Akhanlı y Hennig (2022) agrupa jugadores en función de su rendimiento y estilo de juego, mientras que Das et al. (2023) emplea técnicas de clustering para la identificación de sustitutos en el cricket, lo que resulta especialmente relevante para el objetivo de este trabajo.

Asimismo, en el ámbito del análisis avanzado del rendimiento, estudios como Bunker y Thabtah (2019) y Decroos et al. (2019) destacan el uso de modelos de *machine learning* como *gradient boosting*, *random forests* y redes neuronales profundas para estimar métricas complejas de contribución al juego, como el *expected possession value*. Estas metodologías permiten capturar relaciones no lineales e interacciones entre variables físicas, técnicas y contextuales, superando las limitaciones de los modelos lineales tradicionales. De forma complementaria, en deportes como la NBA, trabajos como Cervone et al. (2016) introducen modelos basados en procesos estocásticos y aprendizaje profundo para evaluar decisiones en tiempo real a partir de datos de seguimiento espacial de alta frecuencia.

Por otro lado, en disciplinas con una mayor tradición en el análisis estadístico, como el béisbol o el cricket, se han desarrollado enfoques híbridos que combinan reducción

de dimensionalidad, aprendizaje no supervisado y modelos probabilísticos para la identificación de talento. En este contexto, Baumer, Kaplan y Horton (2015) y Lemmer (2013) emplean modelos bayesianos jerárquicos y técnicas de regularización (lasso y ridge) para mejorar la estabilidad de las estimaciones en situaciones de alta variabilidad o muestras reducidas. Además, trabajos como Miller, Bornn y Adams (2014) aplican técnicas de factorización matricial y sistemas de recomendación para identificar perfiles similares y proponer sustituciones óptimas, lo que guarda una relación directa con los enfoques de clustering considerados en este estudio.

Para determinar qué posiciones resultan más cercanas a la de Antonio Raíllo (DFC), usaremos la tabla 1.1.

| $d_R(a,b)$ | DFC | LI | LD | MCD | MC | MI | MD | MP | EI | ED | DC |
|---|---|---|---|---|---|---|---|---|---|---|---|
| DFC | 0 | 1 | 1 | 1 | 2 | $\sqrt{5}$ | $\sqrt{5}$ | 3 | $\sqrt{10}$ | $\sqrt{10}$ | 4 |
| LI | 1 | 0 | 1 | $\sqrt{2}$ | $\sqrt{5}$ | 2 | $\sqrt{5}$ | $\sqrt{10}$ | 3 | $\sqrt{10}$ | $\sqrt{17}$ |
| LD | 1 | 1 | 0 | $\sqrt{2}$ | $\sqrt{5}$ | $\sqrt{5}$ | 2 | $\sqrt{10}$ | $\sqrt{10}$ | 3 | $\sqrt{17}$ |
| MCD | 1 | $\sqrt{2}$ | $\sqrt{2}$ | 0 | 1 | $\sqrt{2}$ | $\sqrt{2}$ | 2 | $\sqrt{5}$ | $\sqrt{5}$ | 3 |
| MC | 2 | $\sqrt{5}$ | $\sqrt{5}$ | 1 | 0 | 1 | 1 | $\sqrt{2}$ | $\sqrt{2}$ | $\sqrt{2}$ | 2 |
| MI | $\sqrt{5}$ | 2 | $\sqrt{5}$ | $\sqrt{2}$ | 1 | 0 | 1 | $\sqrt{2}$ | 1 | $\sqrt{2}$ | $\sqrt{5}$ |
| MD | $\sqrt{5}$ | $\sqrt{5}$ | 2 | $\sqrt{2}$ | 1 | 1 | 0 | $\sqrt{2}$ | $\sqrt{2}$ | 1 | $\sqrt{5}$ |
| MP | 3 | $\sqrt{10}$ | $\sqrt{10}$ | 2 | $\sqrt{2}$ | $\sqrt{2}$ | $\sqrt{2}$ | 0 | 1 | 1 | 1 |
| EI | $\sqrt{10}$ | 3 | $\sqrt{10}$ | $\sqrt{5}$ | $\sqrt{2}$ | 1 | $\sqrt{2}$ | 1 | 0 | 1 | $\sqrt{2}$ |
| ED | $\sqrt{10}$ | $\sqrt{10}$ | 3 | $\sqrt{5}$ | $\sqrt{2}$ | $\sqrt{2}$ | 1 | 1 | 1 | 0 | $\sqrt{2}$ |
| DC | 4 | $\sqrt{17}$ | $\sqrt{17}$ | 3 | 2 | $\sqrt{5}$ | $\sqrt{5}$ | 1 | $\sqrt{2}$ | $\sqrt{2}$ | 0 |

Tabla 1.1: Matriz de distancias entre posiciones de juego, donde cada valor representa la proximidad relativa entre dos posiciones en el terreno de juego. Adaptado de Akhanlı y Hennig (2022)

En este trabajo se parte de los datos brutos, se construye y depura la base de datos y, posteriormente, se desarrollan cuatro escenarios de análisis:

- Clustering con todas las variables (k-means y jerárquico).
- ACP y posterior clustering.
- Restricción posicional a posiciones cercanas.
- ACP en el subconjunto posicional y posterior clustering.

En cada una de las etapas del análisis se evalúa la cercanía a $\mathbf{x}_r$ con el objetivo de identificar posibles sustitutos. Para ello, se consideran distintos criterios de selección que varían según el escenario analizado, tales como la pertenencia a un mismo clúster en función del método empleado, la restricción por edad o la adecuación a determinadas posiciones en el campo. De este modo, en cada etapa se obtienen conjuntos de candidatos que cumplen condiciones específicas, permitiendo un análisis más flexible y adaptado a distintos contextos.

Este procedimiento es aplicable a cualquier jugador incluido en la base de datos; sin embargo, el objetivo específico es la búsqueda de un sustituto para Antonio Raíllo, considerando su edad y la finalización de su contrato el 30 de junio de 2027.

El presente TFG se estructura en seis capítulos. En el capítulo 2 se describe el proceso de extracción de datos y se realiza un análisis descriptivo de ellos. A continuación, en el capítulo 3 se expone la metodología seguida y el marco teórico. Posteriormente, el capítulo 4 se centra en la caracterización de Antonio Raíllo. Seguidamente, en el capítulo 5 se presentan los resultados derivados de la aplicación de la metodología descrita previamente. Por su parte, en el capítulo 6 se recogen los candidatos seleccionados y se emplea el videojuego *Football Manager 2026* para simular varias temporadas con el sustituto integrado en el equipo. Finalmente el último capítulo recoge las conclusiones del trabajo y plantea posibles líneas futuras de investigación.

CAPÍTULO 2

# DATOS

## 2.1 Fuentes y alcance

La base de datos combina estadísticas de FBref y posiciones detalladas de BeSoccer, centrada en las primeras divisiones de Alemania, España, Francia, Inglaterra e Italia en la temporada 2024-2025. Se consideraron las variables asociadas a los jugadores de campo. El resultado final son 2854 filas y 165 variables, de las cuales 159 son numéricas y 6 cualitativas. Las filas son cualquier jugador que haya disputado al menos un minuto de algún partido de la temporada 2024-25 en liga.

Por un lado, FBref es una página web más dedicada a estadísticas de los equipos y jugadores, tiene más estadística avanzada. Han ampliado horizontes y no solo se encargan ya de fútbol, también manejan páginas webs de fútbol americano o hockey. Dan información de más de 140 competiciones repartidas en 45 países. En la figura 2.1 se puede ver su logo.

Por otro lado, BeSoccer es una app que da información del mundo del fútbol en general, actualmente tiene más de 20 millones de usuarios activos y es uno de los proyectos líderes en cuanto a informar de cualquier cosa relacionada con el fútbol. En la figura 2.2 se puede ver su logo.

Figura 2.1: Logo FBRef, Fuente: Tomado de https://fbref.com/en/

Figura 2.2: Logo BeSoccer, Fuente: Tomado de https://es.besoccer.com

## 2.2 Extracción y construcción

Las estadísticas se obtuvieron con la librería de Python *LanusStats* usando el algoritmo 1, y las posiciones específicas mediante automatización con Selenium sobre BeSoccer usando el algoritmo 2. Para robustecer el scraping se introdujeron pausas aleatorias y reinicios controlados del navegador, revisándose manualmente los casos sin posición detectada. La integración usó el nombre del jugador como clave, unificando duplicados cuando procedía.

**Algorithm 1** Extracción y almacenamiento del conjunto de datos

```
Importar la librería LanusStats (alias ls)
Importar la librería pandas (alias pd)
Inicializar el objeto Fbref
  fbref ← ls.Fbref()
Extraer las estadísticas de temporada de todos los jugadores
  datos ← fbref.get_all_player_season_stats(
    "Big 5 European Leagues", "2024-2025", save_csv = False)
Mostrar el conjunto de datos correspondiente a estadísticas de jugadores de campo
  print(datos[0])
Seleccionarlas
  X ← datos[0]
Convertir los datos en una estructura tabular
  df ← DataFrame(X)
Exportar el conjunto de datos a un archivo CSV sin índice
  df.to_csv("Big_5_European_Leagues_all_stats_LanusStats.csv",
index=False)
```

## 2.3 Limpieza y depuración

Se eliminaron variables redundantes (identificadores replicados entre bloques de estadísticas) y se cambiaron los identificadores de cada columna para adaptarlos al castellano y tener una lectura más sencilla. Al realizar el web scraping para conseguir la posición detallada de cada jugador, hubo varios errores que se tuvieron que rellenar a mano para completar la base de datos (sacando la información de BeSoccer), asimismo, cuando se ha procedido con el trabajo, se han detectado errores en la posición de varios jugadores (jugador que BeSoccer determina como MCD aparece como PT), en estos casos, si fuese necesario se puede revisar y modificar. Aun así, no modifica las estadísticas del jugador por lo que sigue perteneciendo a un clúster similar a los de su estilo de juego.

Una limitación del *scraping* fueron los errores con el navegador, se hizo con la ayuda de un ingeniero informático y la IA. Al principio buscamos *scrapear* sin reiniciar el driver, pero daba error, la IA (Gemini) recomendó reiniciar cada 10 jugadores y el ingeniero reiniciar solo cuando fallara, y finalmente funcionó correctamente.

## 2.4 Narrativa aplicada: insertar a Raíllo en el espacio de datos

Denotamos por $\mathbf{x}_r$ el vector de Antonio Raíllo, que se integra en la matriz $\mathbf{X}$. Un objetivo transversal es estudiar su vecindario geométrico: jugadores $\mathbf{x}_i$ con $d(\mathbf{x}_i, \mathbf{x}_r)$ mínima. Esta perspectiva guía las decisiones metodológicas subsecuentes (normalización, selección de métricas, ACP y elección de índices de validación).

## 2.5 Descripción exploratoria

La base de datos final está compuesta por 2 854 filas, correspondientes a jugadores (incluyendo posibles duplicados derivados de cambios de equipo durante la temporada) y un total de 165 variables. De estas, 159 son de carácter numérico y 6 cualitativas.

### 2.5.1 Variables Cualitativas

En primer lugar, se describen las variables cualitativas:

- `Jugador`: identifica el nombre del jugador.
- `País`: indica el país de origen del jugador (por ejemplo, `es ESP`).
- `Posiciones`: recoge la posición del jugador según la clasificación de FBref.
- `Posicion_Detallada`: especifica la posición del jugador de acuerdo con BeSoccer.
- `Equipo`: señala el club en el que el jugador disputó la temporada 2024–2025.
- `Liga`: indica la competición en la que participó el jugador durante la temporada 2024–2025 (por ejemplo, `es La Liga`).

Con el fin de analizar la procedencia geográfica de los jugadores y la media de edad por país, se elaboró un mapa que muestra la distribución de futbolistas por países europeos y la media de edad de cada uno de ellos (Figura 2.3). Hay que tener en cuenta que cada país pone un límite para que los jugadores puedan jugar en las máximas categorías, en España la edad mínima es 15 años. Actualmente el récord lo tiene Luka Romero debutando con el RCD Mallorca con 15 años, 7 meses y 6 días.

Como se observa en la Figura 2.3, la mayoría de los jugadores proceden de los países correspondientes a las ligas seleccionadas para el estudio, las cuales, como se ha dicho, son las primeras divisiones de Alemania, España, Francia, Inglaterra e Italia.

Observemos en la Figura 2.4 la distribución del año de nacimiento de los jugadores, junto con su estimación de densidad. Se aprecia que la distribución presenta una forma aproximadamente simétrica y unimodal, lo que sugiere una buena aproximación a una distribución normal. No obstante, pueden observarse ligeras desviaciones en los extremos, propias de la naturaleza finita de la muestra y de la estructura real de la población analizada.

Asimismo, se analizaron las posiciones de los jugadores dentro de la base de datos. En primer lugar, se presenta la distribución de posiciones según la clasificación de FBref (Figura 2.5).

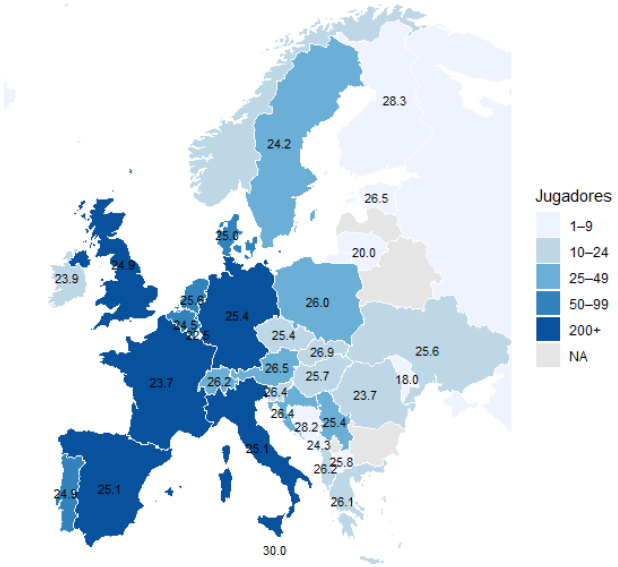


Figura 2.3: Mapa de Europa con el número de jugadores por país y su edad promedio en años. Fuente: Elaboración propia

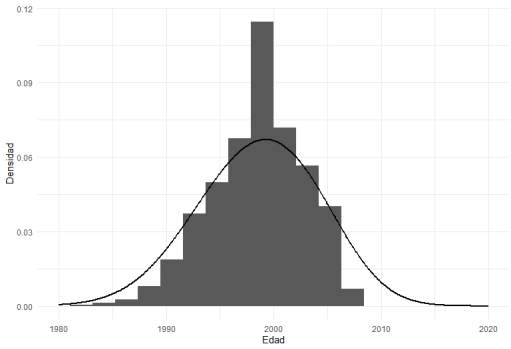


Figura 2.4: Gráfico con la densidad por Año de Nacimiento. Fuente: Elaboración propia

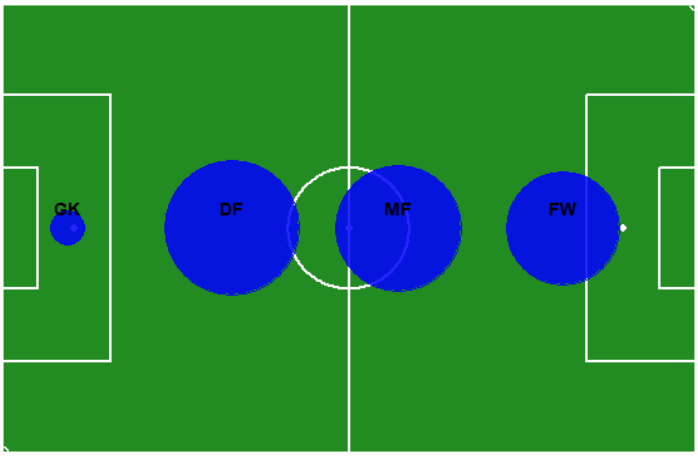


Figura 2.5: Número de jugadores por posición según FBref, a mayor tamaño del círculo mayor número de jugadores. Fuente: Elaboración propia

Tal como se observa en la Figura 2.5, una proporción significativa de los jugadores incluidos en la muestra corresponde a posiciones defensivas. En concreto, la distribución por posiciones es la siguiente: 7.43 % porteros, 35.81 % defensas, 31.53 % mediocampistas y 25.23 % delanteros.

A continuación, se presenta la distribución de posiciones según la clasificación de BeSoccer, que proporciona un mayor nivel de detalle (Figura 2.6). En particular, los jugadores que ocupan la posición de defensa central representan el 18.96 % del total de la muestra.

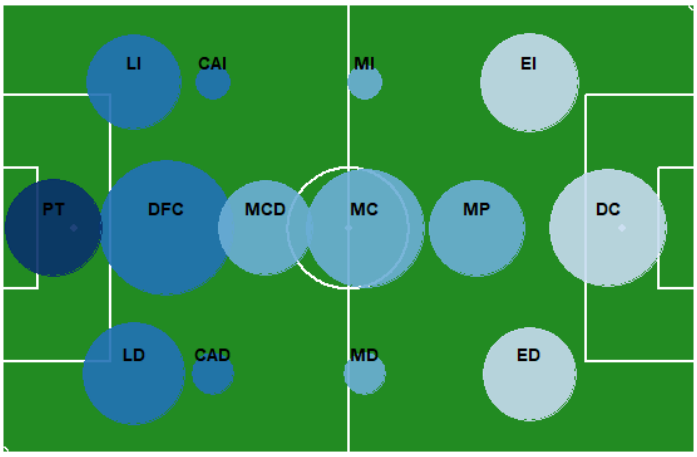


Figura 2.6: Número de jugadores por posición según BeSoccer, a mayor tamaño del círculo mayor número de jugadores. Fuente: Elaboración propia

### 2.5.2 Variables Cuantitativas

En cuanto a las variables cuantitativas, la base de datos incluye, entre otras, las siguientes:

- `Edad`: edad del jugador en el momento de la extracción de los datos (junio de 2025).
- `Minutos_totales`: número total de minutos disputados en competición liguera durante la temporada 2024–2025.
- `Goles`: número de goles anotados en liga durante la temporada 2024–2025.

Dado que el objetivo del estudio es identificar posibles sustitutos para Antonio Raíllo, se analizaron sus percentiles en distintas variables de rendimiento, prestando especial atención a aquellas en las que presenta valores extremos, tanto elevados como bajos. Este análisis permite identificar los aspectos del juego en los que el jugador destaca de manera significativa, así como aquellos en los que su aportación es limitada en comparación con el resto de la muestra.

En la Tabla 2.1 se recogen algunas de las variables más representativas en las que Antonio Raíllo muestra un rendimiento especialmente diferencial, ya sea por situarse en percentiles muy elevados o en el percentil mínimo.

Tabla 2.1: Percentiles de Antonio Raíllo en variables seleccionadas (temporada 2024–2025)

| **Variable** | **Percentil** |
|---|---|
| `Bloqueos_tiro` | 99.75 |
| `Despejes` | 99.68 |
| `Duelos_aereos_ganados` | 99.65 |
| `Penaltis_recibidos` | 0.00 |
| `Penaltis_concedidos` | 0.00 |
| `Goles_en_propia` | 0.00 |

Entre las variables en las que el jugador sobresale de forma positiva se encuentran aquellas relacionadas con el rendimiento defensivo. En particular, Antonio Raíllo presenta valores extremadamente elevados en:

- `Bloqueos_tiro`: número de disparos bloqueados en competición liguera durante la temporada 2024–2025.
- `Despejes`: número de despejes realizados, entendidos como acciones defensivas destinadas a alejar el balón de la zona de peligro.
- `Duelos_aereos_ganados`: número de duelos aéreos ganados en liga, considerando como tales aquellas acciones en las que se recupera la posesión o se impide el avance del rival.

Por el contrario, se identificaron un total de 26 variables en las que Antonio Raíllo se sitúa en el percentil 0, lo que indica una aportación mínima en dichos aspectos del juego en comparación con el resto de jugadores analizados. A modo ilustrativo, se destacan las siguientes:

- `Penaltis_recibidos`: número de penaltis recibidos por el jugador en liga durante la temporada 2024–2025.
- `Penaltis_concedidos`: número de penaltis cometidos por el jugador en liga durante la temporada 2024–2025.
- `Goles_en_propia`: número de goles en propia puerta anotados en liga durante la temporada 2024–2025.

Este patrón refuerza el perfil de Antonio Raíllo como un defensor con una elevada contribución en acciones defensivas directas, especialmente en situaciones aéreas y de protección del área. En este sentido, sus altos valores en variables como despejes, bloqueos y duelos aéreos ganados son característicos de centrales con un rol más posicional, orientado a la defensa en bloque y a la neutralización de acciones de peligro del rival. Por el contrario, su escasa presencia en determinadas variables refleja una menor participación en acciones menos frecuentes o de carácter más situacional, lo que resulta coherente con un perfil especializado en tareas defensivas específicas. En conjunto, estos resultados permiten caracterizar a Raíllo como un defensa central de corte clásico, cuya aportación se concentra en la solidez defensiva y la protección del área.

Con el objetivo de explorar la relación entre las variables numéricas, se construyeron dos gráficos de correlación, uno con las variables ordenadas según el método *hclust* que se muestra en la Figura 2.7b y otro con las variables sin ordenar, que se muestra en la Figura 2.7a.

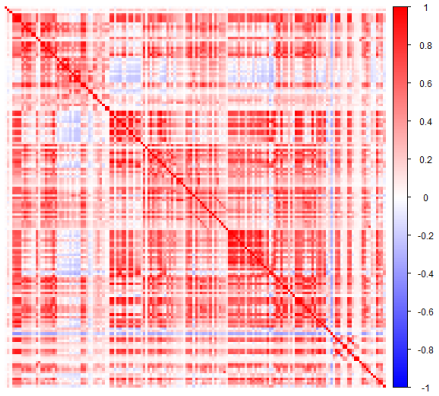


(a) Sin ordenación

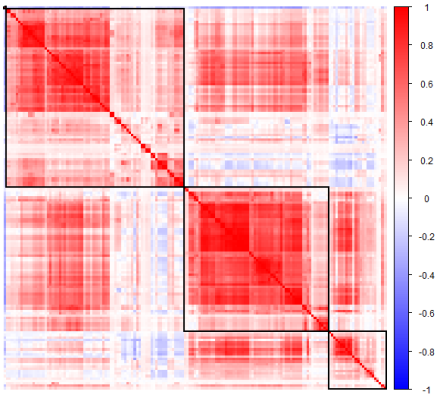


(b) Con *hclust*

Figura 2.7: Matrices de correlación entre las variables numéricas. Los tonos rojos indican correlaciones positivas cercanas a 1, los azules indican correlaciones negativas cercanas a -1 y los tonos claros valores próximos a 0. En la derecha, las variables se ordenan mediante agrupamiento jerárquico, lo que permite identificar bloques de variables altamente correlacionadas. Fuente: Elaboración propia.

Al agrupar las variables en cuatro conjuntos, se identifican bloques bien definidos, representados por los cuadrados oscuros del gráfico, donde cada grupo reúne variables que presentan una elevada interrelación entre sí.

Tras la descripción detallada de la base de datos y de las variables consideradas realizada en este capítulo, el siguiente paso consiste en definir los métodos de análisis que permitirán identificar al jugador o jugadores más similares a Antonio Raíllo. Para ello, en el próximo capítulo se presentará la metodología empleada, basada en técnicas de reducción de la dimensionalidad y algoritmos de agrupamiento, con el objetivo de detectar perfiles de jugadores comparables a partir de sus características estadísticas.

**Algorithm 2** Extracción de la posición de jugadores mediante BeSoccer

**Require:** Archivo CSV con columna `Jugador`
**Ensure:** Archivo CSV con columnas `Player`, `Posicion`

```
function NuevoDriver
    Configurar opciones de Chrome
    Crear driver uc.Chrome con version_main = 142
    Establecer tiempos máximos de carga
    return driver
end function
procedure ProcesarJugadores
    Leer archivo CSV de entrada
    if el archivo no existe then
        Terminar el procedimiento
    end if
    Obtener lista de jugadores únicos
    Inicializar driver usando NuevoDriver
    Inicializar lista RESULTADOS
    for cada jugador en la lista do
        Construir la URL de búsqueda del jugador
        intentos ← 0
        exito ← false
        while intentos < 3 and exito = false do
            Acceder a la URL del jugador
            Esperar un tiempo aleatorio
            if existen resultados de búsqueda then
                Acceder al primer resultado
                Esperar un tiempo aleatorio
            end if
            if se encuentra la posición del jugador then
                posicion ← texto extraído
                Añadir (jugador, posicion) a RESULTADOS
                exito ← true
            else
                intentos ← intentos + 1
                Reiniciar el navegador
            end if
        end while
        if exito = false then
            Añadir (jugador, "ERROR") a RESULTADOS
        end if
    end for
    Cerrar el navegador
    Guardar RESULTADOS en un archivo CSV
end procedure
```

CAPÍTULO 3

# METODOLOGÍA DE ANÁLISIS

## 3.1 Distancias, estandarización y motivación geométrica

Trabajamos principalmente con distancia euclídea y su versión al cuadrado, tras estandarización cuando procede, para evitar que escalas heterogéneas distorsionen la geometría. Dado que $p$ es elevado y existen bloques correlacionados, la reducción de dimensionalidad mediante ACP ayuda a concentrar la varianza en pocas direcciones interpretables y a estabilizar las distancias relativas.

## 3.2 Clustering jerárquico y particional

### 3.2.1 Clustering jerárquico

El análisis jerárquico de conglomerados se fundamenta en un proceso secuencial de particiones. Este proceso puede comenzar con un único grupo que incluye a todos los individuos y llegar, de forma progresiva, hasta una descomposición completa en la que cada observación constituye su propio conglomerado. Existen dos grandes aproximaciones:

a) **Métodos aglomerativos**: parten de los individuos de manera aislada y realizan fusiones sucesivas hasta obtener un solo grupo.

b) **Métodos divisivos**: inician con un conglomerado único que contiene a todos los individuos y lo dividen sucesivamente en subgrupos más pequeños.

Ambas aproximaciones son irreversibles: una vez realizada una fusión o una partición, no es posible revertirla. En consecuencia, el investigador debe establecer un criterio de detención que permita decidir cuál es el número óptimo de conglomerados.

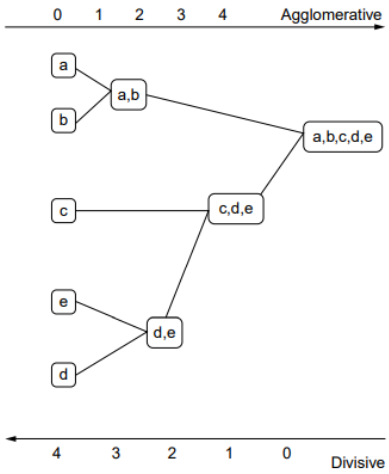


Figura 3.1: Ejemplo de estructura jerárquica en forma de árbol. Fuente: Tomado de Kaufman y Rousseeuw (1990).

**Métodos aglomerativos**

El criterio que define la distancia entre conglomerados es fundamental en los métodos aglomerativos. Entre los más habituales se encuentran:

- **Enlace simple (vecino más próximo):** la distancia entre dos grupos se define como la mínima distancia entre pares de elementos pertenecientes a cada grupo:

$$d(A,B) = \min_{i \in A,\, j \in B} d(x_i, x_j).$$

- **Enlace completo:** la distancia entre dos grupos se define como la máxima distancia entre pares de elementos de ambos grupos:

$$d(A,B) = \max_{i \in A,\, j \in B} d(x_i, x_j).$$

- **Enlace promedio:** la distancia entre dos grupos corresponde a la media de todas las distancias entre pares de elementos de ambos grupos:

$$d(A,B) = \frac{1}{|A||B|} \sum_{i \in A} \sum_{j \in B} d(x_i, x_j).$$

Estos tres enfoques trabajan sobre matrices de proximidad. Por el contrario, el agrupamiento por centroide (UPGMC) utiliza directamente la matriz de datos y fusiona los grupos en función de la similitud de sus medias vectoriales. Una variante es el método ponderado de agrupamiento por pares utilizando centroides (WPGMC), donde los centroides de los conglomerados fusionados se ponderan equitativamente, evitando que los grupos de mayor tamaño dominen sobre los más pequeños.

Otro enfoque relevante es el método de Ward, en el que se selecciona la fusión que minimiza el incremento de la suma de cuadrados del error total dentro de los grupos. Formalmente:

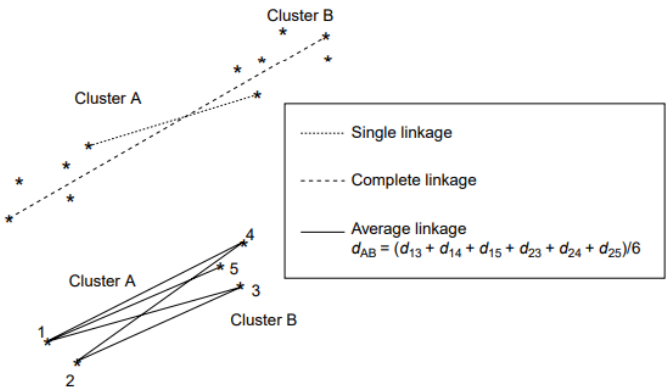


Figura 3.2: Ejemplos de distancias intergrupales: simple, completa y promedio. Tomado de Everitt et al. (2011).

$$E = \sum_{m=1}^{g} E_m, \quad E_m = \sum_{l=1}^{n_m} \sum_{k=1}^{p} \left(x_{ml,k} - \overline{x}_{m,k}\right)^2, \tag{3.1}$$

donde $\overline{x}_{m,k}$ es la media del conglomerado $m$ para la variable $k$, y $x_{ml,k}$ el valor de dicha variable para el individuo $l$ del conglomerado $m$.

La fórmula de recurrencia general que engloba los distintos métodos aglomerativos es la denominada expresión de Lance–Williams:

$$d_{k(ij)} = \alpha_i d_{ki} + \alpha_j d_{kj} + \beta d_{ij} + \gamma |d_{ki} - d_{kj}|, \tag{3.2}$$

donde los coeficientes $\alpha_i, \alpha_j, \beta$ y $\gamma$ determinan el tipo de método empleado.

Tabla 3.1: Condiciones de admisibilidad y parámetros de Lance–Williams para distintos métodos de agrupamiento jerárquico.

| | **Condiciones de admisibilidad** | | | | **Parámetros de Lance–Williams** | | |
|---|---|---|---|---|---|---|---|
| **Método** | U | C | P | M | $\alpha_i$ | $\beta$ | $\gamma$ |
| Enlace simple | N | N | Y | Y | $\frac{1}{2}$ | 0 | $-\frac{1}{2}$ |
| Enlace completo | N | N | Y | Y | $\frac{1}{2}$ | 0 | $\frac{1}{2}$ |
| Enlace promedio | N | N | N | N | $\frac{n_i}{n_i+n_j}$ | 0 | 0 |
| Centroide | Y | N | N | N | $\frac{n_i}{n_i+n_j}$ | $-\frac{n_i n_j}{(n_i+n_j)^2}$ | 0 |
| Mediana | Y | N | Y | N | $\frac{1}{2}$ | $-\frac{1}{4}$ | 0 |
| Método de Ward | N | Y | N | N | $\frac{n_i+n_k}{n_i+n_j+n_k}$ | $-\frac{n_k}{n_i+n_j+n_k}$ | 0 |

U = ultramétrica; C = convexa; P = proporcional a los puntos; M = monótona.
$n_i$, $n_j$ y $n_k$ representan los tamaños de los clústeres implicados en la fusión.

Tabla 3.2: Condiciones de admisibilidad y parámetros de Lance–Williams (Tomado de Everitt et al. (2011)).

### Limitaciones de los métodos aglomerativos

Uno de los inconvenientes más frecuentes es el encadenamiento, típico del enlace simple. Para ilustrarlo, considérese la simulación de 50 observaciones generadas a partir de dos distribuciones normales bivariadas con medias $(0,0)$ y $(4,4)$ y matriz de covarianza

$$\Sigma = \begin{pmatrix} 16.0 & 1.5 \\ 1.5 & 0.25 \end{pmatrix}.$$

A los datos se añadieron dos puntos intermedios para mostrar cómo el método de enlace simple puede fusionar progresivamente ambos grupos, perdiendo la estructura real.

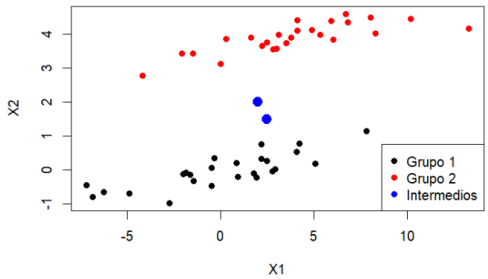


Figura 3.3: Ejemplo de encadenamiento en un conjunto simulado. Fuente: Elaboración propia, ejemplo adaptado de Everitt et al. (2011).

Dando como resultado los clústers que se ven en la Figura 3.4 (siguiendo distintos criterios de enlace).

Para el clustering en este ejemplo se ha usado la distancia euclidiana. Se observa que el enlace simple agrupa casi todos los puntos en un único conglomerado, dejando aislado un valor atípico. Aunque no refleja la separación real de los dos grupos, puede ser útil para identificar *outliers*. Por su parte, los métodos de enlace completo y promedio tampoco logran una partición adecuada, ya que tienden a formar conglomerados aproximadamente esféricos.

### Métodos divisivos

Los métodos divisivos siguen una lógica opuesta: parten de un conglomerado global y lo dividen sucesivamente en subconjuntos. El número de divisiones posibles de un grupo de $n$ elementos es $2^{n-1} - 1$, lo que hace que su aplicación general sea costosa computacionalmente. Sin embargo, cuando los datos están codificados en variables binarias, su uso resulta más eficiente.

### Métodos monotéticos

En este caso, cada división se basa en una única variable. Para decidir cuál emplear, se utilizan criterios como la reducción de heterogeneidad o la asociación con otras variables.

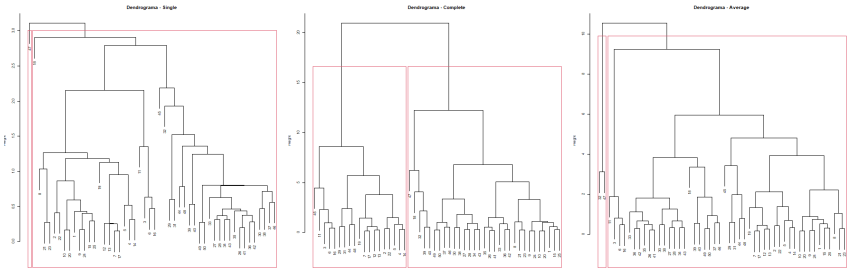

(a) Dendrogramas obtenidos con distintos criterios de enlace.

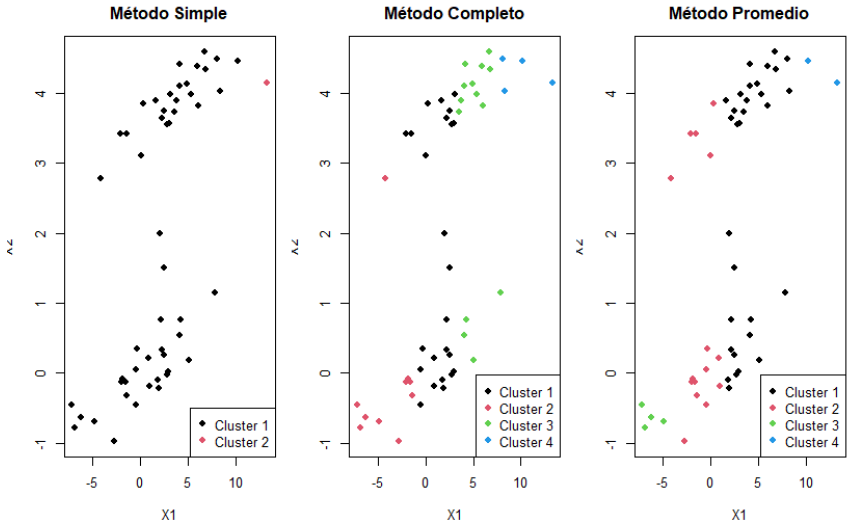


(b) Agrupaciones resultantes a partir de diferentes métodos.

Figura 3.4: Resultados del proceso jerárquico en un conjunto simulado. Fuente: Elaboración propia, ejemplo adaptado de Everitt et al. (2011).

Un criterio de homogeneidad es el *contenido de información* (Lance y Williams 1967):

$$C = pn\log n - \sum_{k=1}^{p} \left[ f_k \log f_k + (n - f_k)\log(n - f_k) \right], \tag{3.3}$$

donde $f_k$ es el número de individuos que poseen el atributo $k$.

Otra posibilidad es el análisis de asociación entre variables binarias, con indicadores como:

$$|ad - bc| \tag{3.4}$$

$$(ad - bc)^2 \tag{3.5}$$

$$\frac{(ad - bc)^2 n}{(a+b)(a+c)(b+d)(c+d)} \tag{3.6}$$

$$\sqrt{\frac{(ad-bc)^2 n}{(a+b)(a+c)(b+d)(c+d)}} \tag{3.7}$$

$$\frac{(ad-bc)^2}{(a+b)(a+c)(b+d)(c+d)} \tag{3.8}$$

En cada etapa, la división se determina según la presencia o ausencia de la variable cuya asociación con las demás alcanza el valor máximo. Los dos primeros criterios ((3.4) y (3.5)) presentan la ventaja de no generar problemas computacionales, incluso cuando alguno de los totales marginales es nulo. Por su parte, los tres últimos ((3.6), (3.7) y (3.8)) se encuentran relacionados, respectivamente, con la estadística chi-cuadrado tradicional, su raíz cuadrada y el coeficiente de correlación de Pearson.

Estos métodos permiten imputar valores ausentes con base en la variable más asociada, facilitando su aplicación en contextos como la medicina o la arqueología. Sin embargo, si una variable es poco frecuente o no se combina con otras, puede generar divisiones poco representativas.

Un desarrollo posterior fue el propuesto por Piccarreta y Billari (2007), basado en la lógica de los árboles de clasificación y regresión (CART). En este caso, la *impureza* de un conglomerado se mide mediante distancias *Optimal Matching Analysis* (OMA), y las divisiones se realizan seleccionando la variable que maximiza la homogeneidad de los grupos resultantes.

#### Métodos politéticos

A diferencia de los anteriores, estos métodos utilizan simultáneamente todas las variables. Un ejemplo es el procedimiento de MacNaughton-Smith et al. (1964), que inicia localizando el objeto más alejado del resto y lo convierte en centroide de un nuevo grupo, incorporando después los elementos más próximos. Kaufman y Rousseeuw (1990) desarrollaron el algoritmo `DIANA`, implementado en R, cuyo funcionamiento se asemeja a la división de un partido político: el miembro más disconforme crea un nuevo partido, seguido de quienes comparten su postura.

### Propiedades matemáticas

El análisis jerárquico cumple o no ciertas propiedades que condicionan su interpretación. Una de ellas es la ultramétrica (U), asociada a la posibilidad de representar la estructura jerárquica mediante un dendrograma. En términos formales:

$$h_{ij} \leq \text{máx}(h_{ik}, h_{jk}) \quad \forall i, j, k, \tag{3.9}$$

donde $h_{ij}$ es la distancia entre los clústeres $i$ y $j$. Una forma alternativa de expresarlo es que, dado un conjunto de tres objetos, las dos distancias mayores entre ellos son iguales. Esta condición no se cumple en general en las matrices de proximidad, pero sí en las alturas de fusión en muchos métodos jerárquicos.

La falta de ultrametricidad puede provocar inversiones o reversiones. Las primeras no siempre suponen un problema, ya que pueden señalar zonas sin estructura definida. Las reversiones, en cambio, dificultan considerablemente la interpretación de la jerarquía, como ocurre en los métodos de centroide y de mediana (Morgan y Ray (1995); Murtagh (1985); Gower (1990)).

Otra propiedad de interés es la conservación del espacio. Un método la cumple si:

$$d_{iuv} \leq d_{i(uv)} \leq D_{iuv}, \tag{3.10}$$

donde $d_{iuv}$ y $D_{iuv}$ son la mínima y la máxima distancia entre el objeto $i$ y los conglomerados $u$ y $v$, respectivamente, y $d_{i(uv)}$ es la distancia al conglomerado resultante.

Fisher y Van Ness (1971) introdujeron varias condiciones de admisibilidad, entre ellas la admisibilidad bien estructurada, que exige que todas las distancias intra-grupo sean menores que las inter-grupo. Mirkin (1996) demostró que esta condición es equivalente a la conservación del espacio bajo las siguientes condiciones $\forall x, y$ tales que $0 < x < 1$ y $y > 0$:

$$\begin{aligned} &\alpha(x, y) + \alpha(1 - x, y) = 1; \\ &\beta(x, 1 - x, y) = 0; \\ &|\gamma(y)| \leq \alpha(x, y), \end{aligned} \tag{3.11}$$

donde $\alpha, \beta$ y $\gamma$ son los parámetros de la fórmula de recurrencia (3.2) expresados como funciones de los tamaños de los clústeres, con $x = n_k/n_+$, $y = n_i/n_+$ y $z = n_j/n_+$, donde $n_+ = n_i + n_j + n_k$

Otras propiedades relevantes incluyen:

- **Admisibilidad convexa (C)**: garantiza que los conglomerados no se superpongan entre sí. Esta condición solo es aplicable cuando los grupos se encuentran definidos en un espacio euclidiano. En ausencia de información adicional sobre la estructura de los datos, resulta recomendable evitar intersecciones de este tipo, aunque diversos métodos clásicos de agrupamiento no cumplen estrictamente esta propiedad.

- **Admisibilidad proporcional a los puntos (P)**: adquiere relevancia en contextos donde pueden existir observaciones repetidas dentro de la muestra, incluso cuando diferentes objetos presentan características idénticas. Algunos programas de análisis permiten asignar pesos a las observaciones para reflejar dichas repeticiones. Además, esta propiedad incrementa la robustez del procedimiento en conjuntos de datos donde ciertas observaciones difieren solo de forma marginal.

- **Admisibilidad monótona (M)**: resulta apropiada en situaciones en las que la única información fiable es el orden relativo de las distancias. Esto suele ocurrir cuando la matriz de proximidad se construye a partir de valoraciones subjetivas, como en estudios de mercado basados en matrices de preferencias o de sustitución de marcas.

**Métodos para grandes conjuntos de datos**

En contextos con gran volumen de información se han desarrollado variantes que combinan una fase preliminar de preagrupamiento con técnicas jerárquicas. Entre las más destacadas se encuentran:

- **BIRCH**: resume las regiones densas del espacio de datos y posteriormente aplica un método jerárquico basado en centroide sobre estos resúmenes.
- **CURE**: selecciona un conjunto reducido de puntos representativos de cada conglomerado, ajustados hacia el centroide, lo que permite manejar valores atípicos y formas no esféricas.
- **TwoStep Cluster** (SPSS): comienza con una fase de preagrupamiento para detectar regiones densas y, posteriormente, aplica técnicas basadas en modelos, eliminando los conglomerados de baja densidad antes del paso jerárquico.

## 3.3 Clustering particional (*K-Means* y *K-Medoids*)

### 3.3.1 *K-Means*

El método de agrupamiento *K-Means* (Hastie, Tibshirani y Friedman 2009) tiene como objetivo identificar un conjunto de $K$ conglomerados y sus respectivos centroides a partir de un conjunto de datos no etiquetado. El investigador debe fijar previamente el número deseado de conglomerados, $K$, tras lo cual el algoritmo selecciona $K$ puntos iniciales (centroides provisionales) $p_i$, normalmente de forma aleatoria, con $i \in \{1, \ldots, K\}$.

Cada punto del conjunto de datos se asigna al conglomerado cuyo centroide se encuentre más próximo, de acuerdo con la distancia establecida. Una vez definidos los grupos, se actualizan los centroides[1] y se repiten las etapas de asignación y actualización hasta que el procedimiento converge.

Este método es adecuado para variables cuantitativas, utilizando habitualmente la distancia euclidiana al cuadrado como medida de disimilitud:

$$d(x_i, x_{i'}) = \sum_{j=1}^{p} (x_{ij} - x_{i'j})^2 = \|x_i - x_{i'}\|^2. \tag{3.12}$$

La dispersión total dentro de los conglomerados puede expresarse como:

$$\begin{aligned} W(C) &= \frac{1}{2} \sum_{k=1}^{K} \sum_{C(i)=k} \sum_{C(i')=k} \|x_i - x_{i'}\|^2 \\ &= \sum_{k=1}^{K} N_k \sum_{C(i)=k} \|x_i - \bar{x}_k\|^2, \end{aligned} \tag{3.13}$$

donde $\bar{x}_k = (\bar{x}_{1k}, \ldots, \bar{x}_{pk})$ es el vector medio del $k$-ésimo conglomerado y $N_k = \sum_{i=1}^{N} I(C(i) = k)$ representa el número de elementos que lo componen.

El criterio se minimiza asignando las $N$ observaciones a los $K$ grupos de modo que, dentro de cada conglomerado, la disimilitud media de las observaciones respecto a su centroide sea mínima. En otras palabras, el método busca particiones que minimicen la variabilidad interna y maximicen la separación entre conglomerados.

[1] Media aritmética de los puntos pertenecientes a cada conglomerado.

### 3.3.2 *K-Medoids*

Cuando los datos incluyen variables no cuantitativas o se desea utilizar una medida de disimilitud distinta de la euclidiana al cuadrado, una alternativa adecuada es el método *K-Medoids*. Su funcionamiento es similar al de *K-Means*, pero permite emplear cualquier métrica o matriz de proximidad. La diferencia principal radica en que el centro de cada conglomerado debe corresponder a una observación real del conjunto de datos, denominada **medoide**: Valor de los datos más cercano al centroide.

Este método puede aplicarse tanto a matrices de datos como a matrices de proximidad. A pesar de su mayor coste computacional, ofrece mayor robustez frente a valores atípicos. La función objetivo se define como:

$$i_k^* = \arg \min_{i:C(i)=k} \sum_{C(i')=k} D(x_i, x_{i'}), \tag{3.14}$$

donde $D(x_i, x_{i'})$ representa la disimilitud entre las observaciones $x_i$ y $x_{i'}$, e $i_k^*$ es el índice del medoide, es decir, el elemento que minimiza la distancia total a los demás puntos del conglomerado $k$. En consecuencia, $m_k = x_{i_k^*}$ constituye el centro representativo del grupo.

### 3.3.3 Algoritmo de Hartigan y Wong

Una de las versiones más eficientes del algoritmo *K-Means* fue desarrollada por Hartigan y Wong (1979), como extensión del trabajo original de Hartigan (1975). Este procedimiento busca una partición localmente óptima que minimice la suma de cuadrados dentro de los conglomerados mediante la transferencia iterativa de puntos entre grupos.

El algoritmo requiere como entrada una matriz de $M$ observaciones en $N$ dimensiones y una matriz con $K$ centroides iniciales en el mismo espacio. Se denota por $NC(L)$ el número de elementos del conglomerado $L$ y por $D(I, L)$ la distancia euclidiana entre el punto $I$ y el centro del grupo $L$.

El procedimiento general consta de las siguientes etapas:

1. **Inicialización:** Para cada punto $x_i$ ($i = 1, \ldots, N$), se calcula el conglomerado más cercano y el segundo más cercano en términos de distancia euclidiana al cuadrado. Se asigna $x_i$ al conglomerado más próximo:

$$C(i) = \arg\min_k \|x_i - m_k\|^2.$$

2. **Actualización de centros:** Se recalculan los centroides $m_k$ como la media de los puntos asignados a cada conglomerado.

3. **Conjunto activo:** Se marcan todos los conglomerados como *activos*, indicando que son susceptibles de cambio en las siguientes fases.

4. **Fase de transferencia óptima (OPTRA):** Se recorren los puntos $x_i$ en un orden determinado. Sea $L$ el conglomerado actual de $x_i$. Para cada conglomerado candidato $L_2 \neq L$, se evalúa el coste de extraer $x_i$ de $L$ y añadirlo a $L_2$ mediante:

$$R_1(i, L) = \frac{n_L}{n_L - 1} \|x_i - m_L\|^2, \qquad R_2(i, L_2) = \frac{n_{L_2}}{n_{L_2} + 1} \|x_i - m_{L_2}\|^2.$$

Si $\min_{L_2 \neq L} R_2(i, L_2) < R_1(i, L)$, el punto $x_i$ se transfiere al conglomerado que minimiza $R_2$. Posteriormente, se actualizan los centroides $m_L$, $m_{L_2}$ y los tamaños $N_L$, $N_{L_2}$, manteniendo ambos conglomerados como *activos*. Este proceso se repite hasta que no se produzcan más mejoras.

5. Si no quedan conglomerados activos, el algoritmo termina. En caso contrario, continúa con la siguiente fase.

6. **Fase de transferencia rápida (QTRAN):** Para cada punto $x_i$, se identifican su conglomerado actual $L_1$ y el segundo más cercano $L_2$. Se recalculan:

$$R_1(i, L_1) = \frac{N_{L_1}}{N_{L_1} - 1} \|x_i - m_{L_1}\|^2, \qquad R_2(i, L_2) = \frac{N_{L_2}}{N_{L_2} + 1} \|x_i - m_{L_2}\|^2.$$

   Si $R_2(i, L_2) < R_1(i, L_1)$, se traslada $x_i$ al conglomerado $L_2$ y se actualizan los parámetros $m_{L_1}, m_{L_2}, N_{L_1}, N_{L_2}$, marcando ambos como *activos*.

7. Si en la fase QTRAN no se produjo ninguna transferencia, vuelve al paso 4 (OPTRA). En caso contrario, repite el paso 6 hasta que no haya más traslados; después regresa al paso 4.

## 3.4 Índices de validación y comparación de particiones

La partición obtenida mediante un algoritmo de *clustering* depende tanto del método utilizado como de los parámetros empleados e, incluso, del orden en el que se presentan los datos. Por ello, resulta imprescindible disponer de medidas objetivas que permitan evaluar la estructura de los conglomerados y guiar la selección del número óptimo de grupos. En esta sección se presentan algunos de los índices más utilizados con este propósito.

### 3.4.1 Índice *Silhouette*

El índice *Silhouette*, introducido por Rousseeuw (1987), evalúa la coherencia interna de los conglomerados comparando la disimilitud de cada observación con los elementos de su propio grupo y con los de los grupos vecinos. Se define como:

$$\text{Silhouette} = \frac{1}{n} \sum_{i=1}^{n} S(i), \qquad S(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}},$$

donde:

- $a(i) = \frac{\sum_{j \in (C_r \setminus i)} d_{ij}}{n_r - 1}$ representa la disimilitud media entre la observación $i$ y los elementos de su mismo conglomerado $C_r$.
- $b(i) = \min_{s \neq r}\{d_{iC_s}\}$ es la mínima disimilitud media de $i$ con los elementos de cualquier otro conglomerado $C_s$.
- $d_{iC_s} = \frac{\sum_{j \in C_s} d_{ij}}{n_s}$ corresponde a la disimilitud media entre $i$ y los miembros del grupo $C_s$.

El valor del índice oscila entre $-1$ y 1, donde valores cercanos a 1 reflejan conglomerados bien definidos y valores negativos indican posibles asignaciones erróneas. El número óptimo de grupos se determina aquel que maximiza la media global del índice.

### 3.4.2 Estadístico *Gap*

El estadístico *Gap*, propuesto por Tibshirani, Walther y Hastie (2001), compara la dispersión observada de los datos con la esperada bajo una distribución de referencia sin estructura de conglomerados. Se define como:

$$\mathrm{Gap}(q) = \frac{1}{B}\sum_{b=1}^{B} \log W_{qb} - \log W_q,$$

donde $B$ es el número de conjuntos de referencia generados mediante una distribución uniforme y $W_{qb}$ es la dispersión intra-grupo correspondiente al conjunto $b$.

El número óptimo de conglomerados se elige como el menor $q$ que satisfaga:

$$\mathrm{Gap}(q) \geq \mathrm{Gap}(q+1) - s_{q+1},$$

donde $s_q = sd_q\sqrt{1+\frac{1}{B}}$, y $sd_q$ es la desviación estándar de los valores $\{\log W_{qb}\}_{b=1}^{B}$, calculada como:

$$sd_q = \sqrt{\frac{1}{B}\sum_{b=1}^{B}(\log W_{qb} - \hat{l})^2}, \qquad \hat{l} = \frac{1}{B}\sum_{b=1}^{B}\log W_{qb}.$$

El método *Gap* proporciona una estimación robusta y ampliamente aplicable del número de conglomerados, ya que no depende de la métrica específica utilizada en el análisis ni de la escala de los datos originales.

### 3.4.3 Índice de Rand

El índice de Rand (1971) permite cuantificar el grado de acuerdo entre dos particiones obtenidas sobre un mismo conjunto de datos mediante diferentes métodos de agrupamiento. Su cálculo se basa en analizar todos los pares posibles de observaciones, es decir, los $\binom{n}{2}$ pares que pueden formarse a partir de $n$ objetos, y determinar en qué medida ambas particiones coinciden al asignar cada par al mismo o a distintos conglomerados.

El índice se define como:

$$I_{\mathrm{R}} = \frac{2A}{n(n-1)} \in [0,1], \quad A = \binom{n}{2} + 2\sum_{i=1}^{C_1}\sum_{j=1}^{C_2} n_{ij}^2 - \left(\sum_{i=1}^{C_1} n_{i\cdot}^2 + \sum_{j=1}^{C_2} n_{\cdot j}^2\right),$$

$$n_{i\cdot} = \sum_{i=1}^{C_1} n_{ij}, \qquad n_{\cdot j} = \sum_{j=1}^{C_2} n_{ij}.$$

En esta expresión, $C_1$ y $C_2$ representan el número de conglomerados en las dos particiones consideradas, mientras que $n_{ij}$ denota el número de observaciones que pertenecen simultáneamente al clúster $i$ de la primera partición y al clúster $j$ de la segunda.

El índice toma valores entre 0 y 1: un valor de 0 indica ausencia total de coincidencia entre las particiones; mientras que un valor de 1 refleja una coincidencia perfecta.

No obstante, este índice presenta una limitación importante: tiende a aumentar cuando se incrementa el número de conglomerados, lo que puede generar una sobreestimación del grado de acuerdo. Para corregir este efecto, Hubert y Arabie (1985) propusieron el **índice de Rand ajustado**, cuyo rango es $[-1,1]$. En este caso:

- $I_{\text{HA}} = 1$ indica que ambas particiones son idénticas.
- $I_{\text{HA}} = 0$ corresponde al nivel de coincidencia esperado por azar.
- $I_{\text{HA}} < 0$ indica un acuerdo inferior al esperado aleatoriamente. Es decir, las coincidencias observadas entre las dos clasificaciones no solo no son significativas, sino que sugieren una discrepancia sistemática en la asignación de los elementos a los clústeres.

El índice ajustado se considera más fiable, especialmente cuando las particiones difieren en el número de conglomerados o cuando el número de grupos es elevado.

Tras la exposición de la metodología y de las distintas técnicas de análisis de clúster consideradas en este capítulo, en el siguiente capítulo se presentan los resultados obtenidos al aplicar estos métodos sobre el conjunto de datos descrito en el Capítulo 2. De este modo, se analizará cómo las diferentes aproximaciones permiten identificar agrupaciones de jugadores con perfiles similares, prestando especial atención a aquellos más cercanos a Antonio Raíllo, con el fin de evaluar la coherencia y utilidad de los modelos empleados.

CAPÍTULO 4

# RESULTADOS

Cabe indicar que este procedimiento es replicable para cualquier jugador de nuestra base de datos, y nos dará la lista de sus candidatos a sustituto.

En esta sección se presentan los resultados obtenidos al aplicar distintos métodos de *clustering* sobre la base de datos construida. Con el objetivo de evaluar la robustez de las particiones, se han considerado diferentes enfoques metodológicos, combinando técnicas de agrupamiento, índices de validación y transformaciones previas de los datos.

El número de clústeres analizado se ha acotado al intervalo comprendido entre 4 y 10. Esta elección responde a un compromiso entre interpretabilidad y estabilidad: valores demasiado bajos pueden conducir a agrupaciones excesivamente generales, mientras que un número elevado de clústeres dificulta la interpretación y puede dar lugar a grupos poco representativos.

## 4.1 Clustering en el conjunto completo

En primer lugar, se realizó el *clustering* utilizando la totalidad de las variables originales. Se emplearon dos métodos distintos: *k-means*, implementado mediante el algoritmo de Hartigan–Wong, y el método jerárquico aglomerativo con criterio de Ward y distancia euclídea. Para determinar el número adecuado de clústeres se recurrió a los índices de Silueta y de Calinski–Harabasz.

### 4.1.1 Índice de Silueta

De acuerdo con el índice de Silueta, el número óptimo de clústeres es de siete en el caso de *k-means* y de cuatro para el método jerárquico con Ward. Los valores obtenidos se representan en la Figura 4.1 y en la Figura 4.2.

Para evaluar el grado de similitud entre ambas particiones se calculó el índice de Rand ajustado, obteniéndose un valor de 0.335. Dado que el valor máximo de este índice

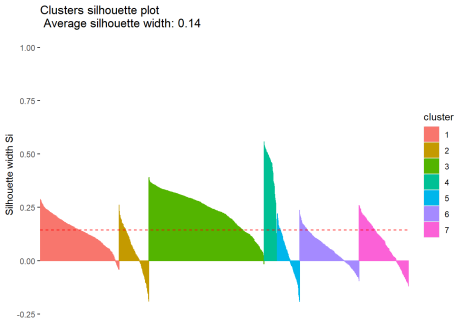


Figura 4.1: Índice de silueta para *k-means* con 7 grupos (El índice medio fue de 0.14). Fuente: Elaboración propia

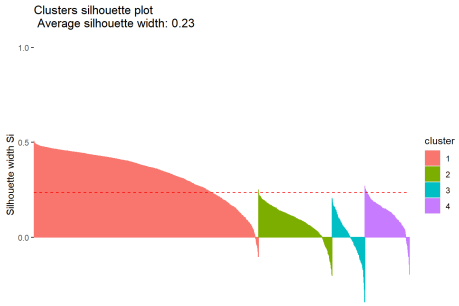


Figura 4.2: Índice de silueta para *Jerárquico* con enlace de Ward con 4 grupos (El índice medio fue de 0.23). Fuente: Elaboración propia

es 1, el resultado indica que las particiones generadas por ambos métodos presentan diferencias notables.

### 4.1.2 Índice de Calinski–Harabasz

Repitiendo el análisis con el índice de Calinski–Harabasz, el número óptimo de clústeres resulta ser cuatro tanto para *k-means* como para el método jerárquico.

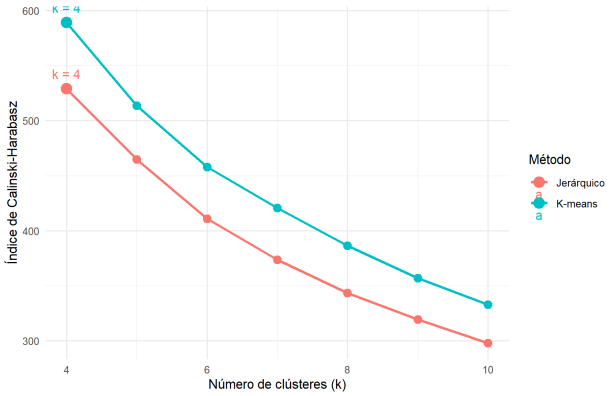


Figura 4.3: Evolución del índice de Calinski-Harabasz según el número de clústeres (k) para los métodos k-means y jerárquico en el conjunto total de jugadores y variables, donde valores más altos indican una mejor separación entre grupos. Fuente: Elaboración propia.

A pesar de coincidir en el número de grupos, el índice de Rand ajustado entre ambas particiones es 0.427, superior al obtenido mediante el índice de Silueta, lo que sugiere una mayor similitud entre los clústeres generados en este caso.

## 4.2 ACP y clustering en espacio reducido

Con el fin de reducir la dimensionalidad del problema y estudiar la estructura interna de los datos, se aplicó un Análisis de Componentes Principales (ACP). Los resultados

indican que las dos primeras componentes explican aproximadamente el 50 % de la varianza total acumulada. Para alcanzar un 80 % de varianza explicada es necesario considerar 19 componentes, mientras que la varianza acumulada alcanza el 100 % en la componente 127.

En la Figura 4.4 se representa la varianza explicada por las diez primeras componentes principales.

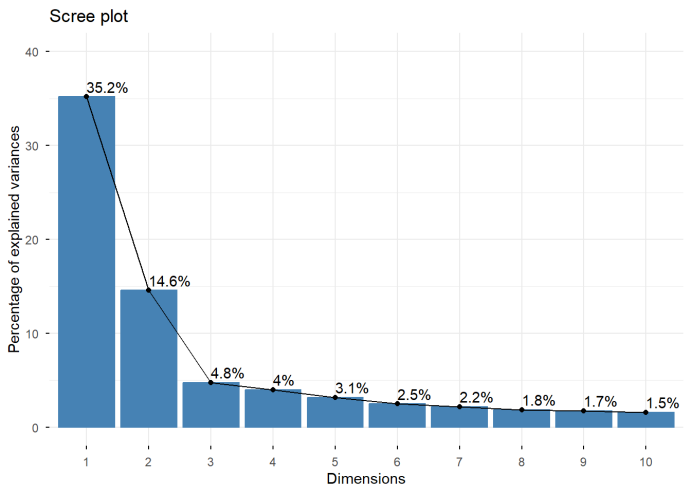


Figura 4.4: Varianza explicada por las diez primeras componentes principales.

Asimismo, se analizó el círculo de correlación de las variables originales proyectadas sobre las dos primeras componentes. Aunque esta representación solo conserva el 50.26 % de la información total, permite obtener una visión general de las relaciones entre las variables y las nuevas dimensiones.

Adicionalmente, se representaron únicamente las 20 variables con mayor contribución al ACP, con el objetivo de facilitar la interpretación.

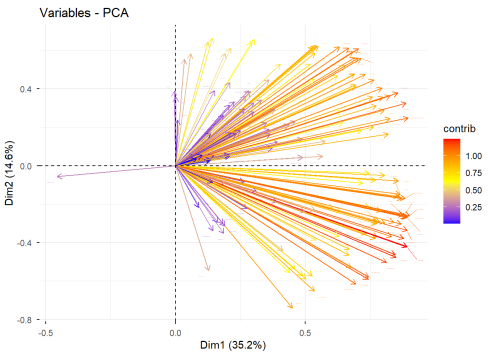


Figura 4.5: Círculo de correlación del ACP. Fuente: Elaboración propia.

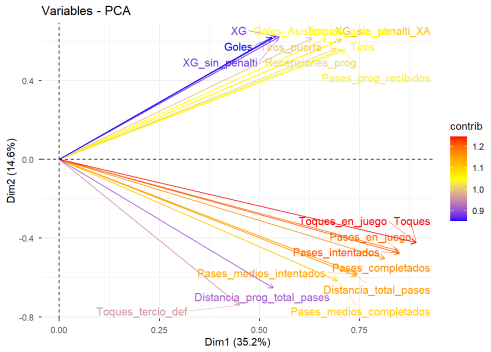


Figura 4.6: Círculo de correlación con las 20 variables más influyentes. Fuente: Elaboración propia.

Una vez aplicado el ACP, repetimos el proceso de *clustering* utilizando las 19 primeras componentes, que preservan aproximadamente el 80 % de la varianza total.

### 4.2.1 Índice de Silueta

Según este índice, el número óptimo de clústeres es de siete para *k-means* y de cuatro para el método jerárquico. El índice de Rand ajustado asociado a estas particiones es de 0.291, lo que indica una baja similitud entre ambos resultados.

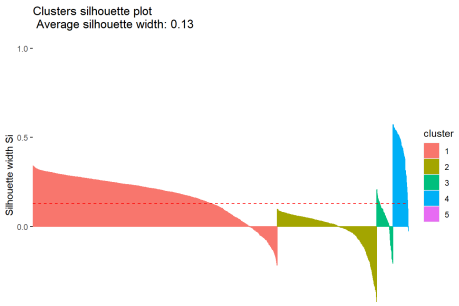


Figura 4.7: Índice de silueta para *k-means* tras el ACP (El índice medio fue de 0.13). Fuente: Elaboración propia.

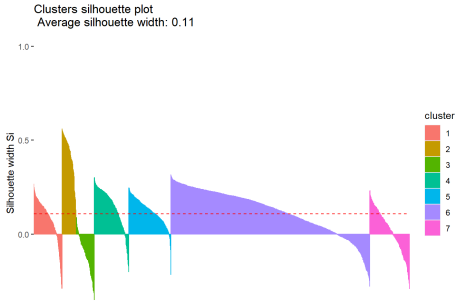


Figura 4.8: Índice de silueta para el método jerárquico tras el ACP (El índice medio fue de 0.11). Fuente: Elaboración propia.

### 4.2.2 Índice de Calinski–Harabasz

En este caso, el índice sugiere diez clústeres para *k-means* y cuatro para el método jerárquico.

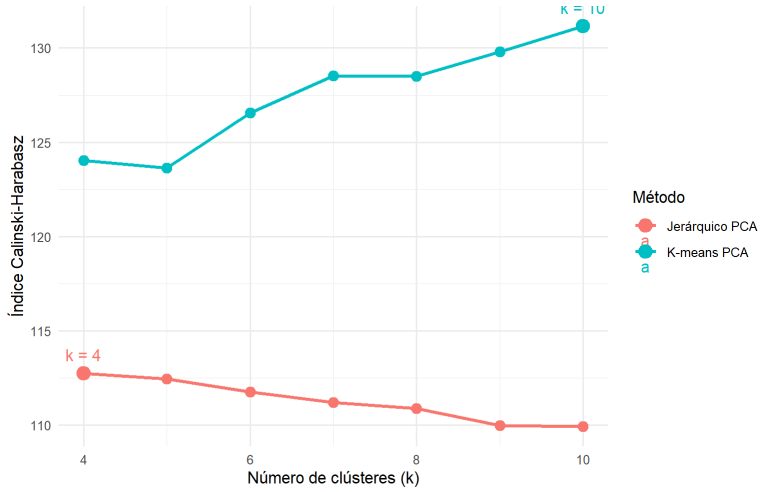


Figura 4.9: Evolución del índice de Calinski-Harabasz según el número de clústeres (k) para los métodos k-means y jerárquico en el conjunto total de jugadores y con las nuevas variables (ACP), donde valores más altos indican una mejor separación entre grupos. Fuente: Elaboración propia.

## 4.3 Clustering con restricción posicional a DFC y posiciones cercanas

Dado que el objetivo principal del estudio es identificar posibles sustitutos de Antonio Raíllo, se restringió el análisis a jugadores que ocupan posiciones similares. Siguiendo la clasificación propuesta por Akhanlı y Hennig (2022), se consideraron las posiciones DFC, LI, LD y MCD, cuya distancia funcional respecto a DFC es menor o igual a uno.

### 4.3.1 Índice de Silueta

Bajo esta restricción, el índice de Silueta indica que el número óptimo de clústeres es de cinco para *k-means* y de siete para el método jerárquico.

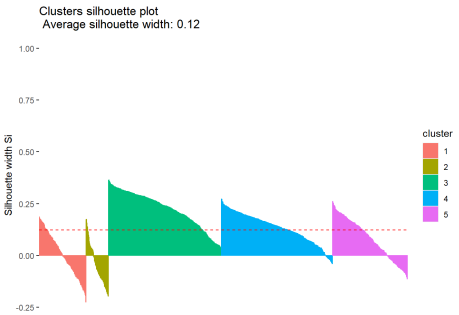


Figura 4.10: Índice de silueta para *k-means* (El índice medio fue de 0.12). Fuente: Elaboración propia.

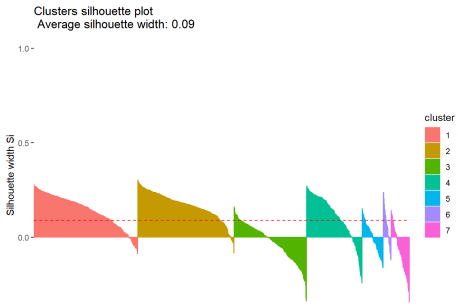


Figura 4.11: Índice de silueta para el método jerárquico (El índice medio fue de 0.09). Fuente: Elaboración propia.

El índice de Rand ajustado para estas particiones es de 0.571, lo que indica una similitud moderada entre los clústeres obtenidos.

### 4.3.2 Índice de Calinski–Harabasz

De acuerdo con este índice, el número óptimo de clústeres es de cuatro para ambos métodos. El valor del índice de Rand ajustado asociado es 0.572.

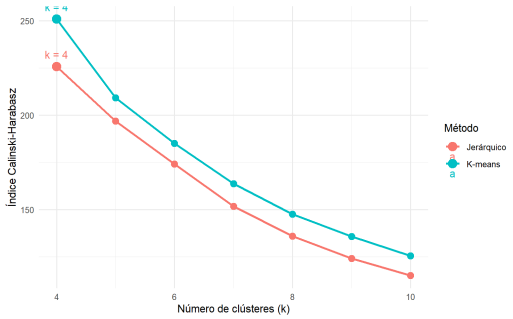


Figura 4.12: Evolución del índice de Calinski-Harabasz según el número de clústeres (k) para los métodos k-means y jerárquico en el conjunto restringido de jugadores y todas las variables iniciales, donde valores más altos indican una mejor separación entre grupos. Fuente: Elaboración propia.

## 4.4 ACP en el subconjunto posicional y clustering

Finalmente, se aplicó nuevamente el ACP considerando únicamente los jugadores de las posiciones seleccionadas. En este caso, se requieren 21 componentes para preservar el 80 % de la varianza total y 128 para alcanzar el 100 %.

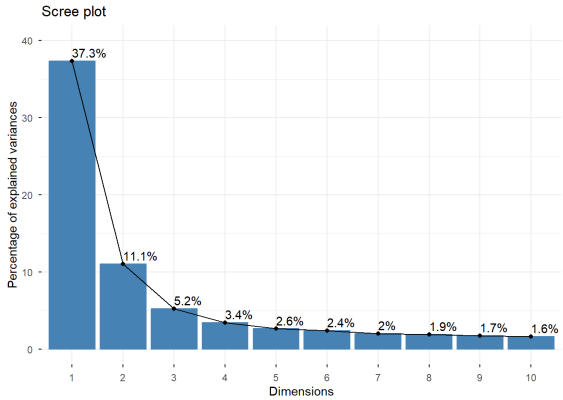


Figura 4.13: Varianza explicada por las diez primeras componentes (posiciones cercanas). Fuente: Elaboración propia.

Se analizaron también los círculos de correlación correspondientes, tanto para el conjunto completo de variables como para las 20 de mayor contribución. En la Figura 4.14 se representan todas las variables consideradas en el ACP mediante el círculo de correlaciones. En dicha representación se observa que la primera componente principal concentra una contribución predominantemente positiva y explica aproximadamente el 37 % de la variabilidad total. Por su parte, la segunda componente principal explica en torno al 11 % de la información y presenta variables con cargas tanto positivas como negativas, agrupadas en dos sectores diferenciados. Finalmente, las variables representadas en color azul muestran una escasa contribución a las dos primeras componentes, por lo que su representación en este plano factorial es reducida. Asimismo, en la Figura 4.15 se muestran las 20 variables con mayor correlación positiva dentro de las dos primeras componentes.

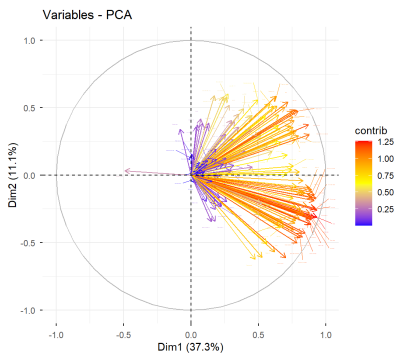


Figura 4.14: Círculo de correlación. Fuente: Elaboración propia.

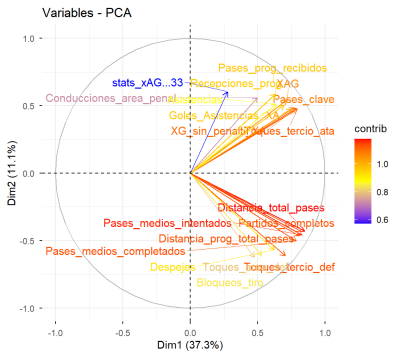


Figura 4.15: Círculo de correlación con las 20 variables principales. Fuente: Elaboración propia.

Asimismo, en la Figura 4.16 se representan los jugadores más próximos a Antonio Raíllo en el espacio definido por las dos primeras componentes principales. Se observa que estos jugadores presentan, en su mayoría, un perfil claramente defensivo, predominando los defensas centrales (DFC). Entre ellos se encuentran jugadores de alto nivel competitivo, como Kim Min-jae (Bayern de Múnich), Rúben Dias (Manchester City) o Jonathan Tah (Bayer Leverkusen), que militan en clubes punteros de sus respectivas ligas. Asimismo, también aparecen jugadores que compiten en equipos de un nivel más cercano al del RCD Mallorca, como Jaka Bijol (Udinese) o Dara O'Shea (Ipswich Town), lo que refuerza la coherencia del análisis en términos de comparabilidad deportiva.

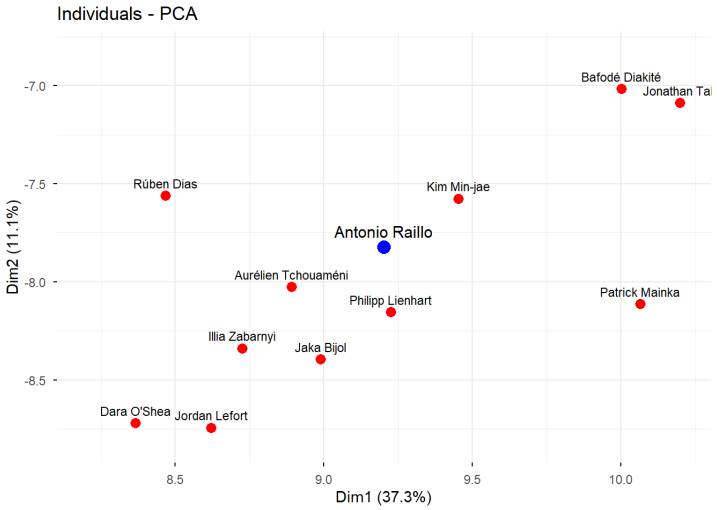


Figura 4.16: Jugadores cercanos a Antonio Raíllo tras el ACP usando las dos primeras componentes. Fuente: Elaboración propia.

### 4.4.1 Índice de Silueta

En este escenario, el índice de Silueta sugiere cinco clústeres tanto para *k-means* como para el método jerárquico.

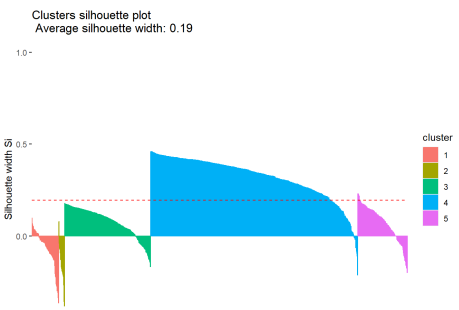


Figura 4.17: Índice de silueta para *k-means* tras ACP (El índice medio fue de 0.19). Fuente: Elaboración propia.

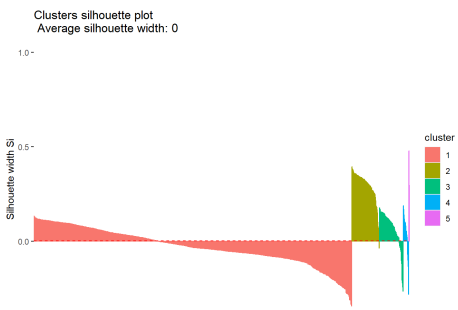


Figura 4.18: Índice de silueta jerárquico tras ACP (El índice medio fue de 0). Fuente: Elaboración propia.

### 4.4.2 Índice de Calinski–Harabasz

Por último, el índice de Calinski–Harabasz indica un número óptimo de diez clústeres para *k-means* y de siete para el método jerárquico.

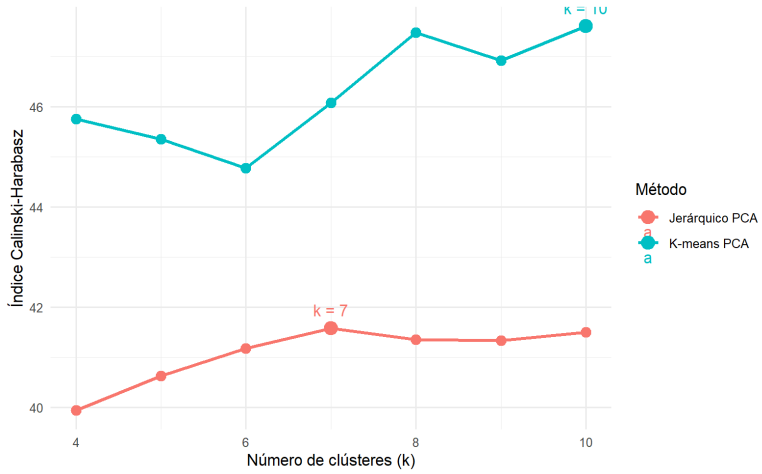


Figura 4.19: Evolución del índice de Calinski-Harabasz según el número de clústeres (k) para los métodos k-means y jerárquico en el conjunto restringido de jugadores y las nuevas variables (ACP), donde valores más altos indican una mejor separación entre grupos. Fuente: Elaboración propia.

## 4.5 Candidatos a sustitutos

A partir de los resultados obtenidos en las distintas configuraciones de *clustering*, se procedió a identificar los jugadores más próximos a Antonio Raíllo, para ello, y con el fin de mantener un criterio homogéneo de comparación entre escenarios, se utilizó la distancia euclídea como medida de proximidad. Esta elección se justifica por su coherencia con los métodos de agrupamiento empleados, en particular k-means y el método jerárquico de Ward, los cuales se fundamentan en la minimización de la variabilidad interna medida mediante distancias euclídeas. Además, al trabajar con variables cuantitativas previamente estandarizadas, la distancia euclídea permite interpretar de forma directa la proximidad entre jugadores en el espacio de características, facilitando la comparación y la identificación de perfiles similares.

El procedimiento seguido fue el mismo en todos los casos: (i) se calcularon los jugadores más cercanos a Raíllo en el espacio de variables considerado (sin reducción y con ACP) y, posteriormente, (ii) se comprobó la pertenencia de dichos jugadores al clúster asignado a Raíllo en cada método e índice de validación. En las Tablas 4.1–4.4 se recogen los diez jugadores más cercanos a Antonio Raíllo en cada una de las configuraciones consideradas. Los tres candidatos seleccionados finalmente como posibles sustitutos aparecen resaltados mediante un formato diferenciado para facilitar su identificación.

### 4.5.1 Ranking con la base de datos completa

En primer lugar, se empleó la base de datos completa (sin ACP). La Tabla 4.1 resume el ranking de cercanía para *k-means* y jerárquico (Ward), bajo los criterios sugeridos por los índices de Silueta y Calinski–Harabasz.

Tabla 4.1: Ranking global (sin ACP) según métodos y métricas de validación

| Pos | Total | Sil KMeans | Sil Jer. | CH KMeans | CH Jer. |
|---|---|---|---|---|---|
| 1 | Johan Vásquez | Johan Vásquez | Johan Vásquez | Johan Vásquez | Johan Vásquez |
| 2 | Ko Itakura | Ko Itakura | Ko Itakura | Ko Itakura | Ko Itakura |
| 3 | Hauke Wahl | Hauke Wahl | Hauke Wahl | Hauke Wahl | Hauke Wahl |
| 4 | Alessio Romagnoli | Alessio Romagnoli | Alessio Romagnoli | Alessio Romagnoli | Alessio Romagnoli |
| 5 | Guillermo Maripán | Guillermo Maripán | Guillermo Maripán | Guillermo Maripán | Guillermo Maripán |
| 6 | Willi Orban | Willi Orban | Willi Orban | Willi Orban | Willi Orban |
| 7 | Robin Koch | Robin Koch | Robin Koch | Robin Koch | Robin Koch |
| 8 | Charlie Cresswell | Charlie Cresswell | Charlie Cresswell | Charlie Cresswell | Charlie Cresswell |
| 9 | James Tarkowski | James Tarkowski | James Tarkowski | James Tarkowski | James Tarkowski |
| 10 | Marc-Oliver Kempf | Marc-Oliver Kempf | Marc-Oliver Kempf | Marc-Oliver Kempf | Marc-Oliver Kempf |

A continuación, se repitió el análisis utilizando las variables transformadas mediante ACP. La Tabla 4.2 recoge los diez jugadores más cercanos bajo las mismas combinaciones de método e índice.

Tabla 4.2: Ranking global (con ACP) según métodos y métricas de validación

| Pos | Total ACP | Sil KMeans ACP | Sil Jer. ACP | CH KMeans ACP | CH Jer. ACP |
|---|---|---|---|---|---|
| 1 | Johan Vásquez | Kevin Schade | César Tárrega | César Tárrega | César Tárrega |
| 2 | Maximilian Beier | Charlie Cresswell | Charlie Cresswell | Charlie Cresswell | Charlie Cresswell |
| 3 | Kévin Pedro | Scott McKenna | Scott McKenna | Scott McKenna | Scott McKenna |
| 4 | Che Adams | Denis Vavro | Denis Vavro | Denis Vavro | Denis Vavro |
| 5 | Johannes Eggestein | Saúl Coco | Saúl Coco | Saúl Coco | Saúl Coco |
| 6 | Lorenzo Lucca | Ko Itakura | Ko Itakura | Ko Itakura | Ko Itakura |
| 7 | Adrian Niño | Jean-Charles Castelletto | Jean-Charles Castelletto | Jean-Charles Castelletto | Jean-Charles Castelletto |
| 8 | Alex Baena | Dan Burn | Dan Burn | Dan Burn | Dan Burn |
| 9 | Virgil van Dijk | Jay Idzes | Jay Idzes | Jay Idzes | Jay Idzes |
| 10 | Morten Thorsby | Willi Orban | Matthijs de Ligt | Willi Orban | Matthijs de Ligt |

### 4.5.2 Ranking restringido a posiciones cercanas a DFC

Dado que Antonio Raíllo desempeña la posición DFC, se consideró también un análisis restringido a posiciones cercanas a DFC. En este caso, el objetivo es reducir la heterogeneidad posicional y centrar la comparación en perfiles funcionalmente más comparables. La Tabla 4.3 presenta los resultados sin ACP.

La Tabla 4.4 muestra el ranking análogo cuando se realiza el *clustering* sobre las componentes principales.

De todas estas listas, vamos a seleccionar los más recurrentes. Aunque en términos de planificación deportiva, esto serviría como una primera criba para que el Director Deportivo del club pueda observar candidatos a sustitutos del jugador.

### 4.5.3 Síntesis de candidatos recurrentes

Para este apartado hemos buscado el valor de mercado de los jugadores en la web Transfermarkt (2026), añadiéndolos a mano en nuestra base de datos solo a los jugadores que nos salían como candidatos a sustituto de Antonio Raíllo.

Tabla 4.3: Ranking de posiciones cercanas a DFC (sin ACP) según métodos y métricas de validación

| Pos | Sil KMeans | Sil Jer. | CH KMeans | CH Jer. |
|---|---|---|---|---|
| 1 | Alessio Romagnoli | Alessio Romagnoli | Alessio Romagnoli | Alessio Romagnoli |
| 2 | Johan Vásquez | Johan Vásquez | Johan Vásquez | Johan Vásquez |
| 3 | Jaka Bijol | Jaka Bijol | Jaka Bijol | Jaka Bijol |
| 4 | Ko Itakura | Ko Itakura | Ko Itakura | Ko Itakura |
| 5 | Guillermo Maripán | Guillermo Maripán | Guillermo Maripán | Guillermo Maripán |
| 6 | Federico Baschirotto | Federico Baschirotto | Federico Baschirotto | Federico Baschirotto |
| 7 | James Tarkowski | James Tarkowski | James Tarkowski | James Tarkowski |
| 8 | Robin Koch | Robin Koch | Robin Koch | Robin Koch |
| 9 | Hauke Wahl | Hauke Wahl | Hauke Wahl | Hauke Wahl |
| 10 | Jay Idzes | Jay Idzes | Jay Idzes | Jay Idzes |

Tabla 4.4: Ranking de posiciones cercanas a DFC (con ACP) según métodos y métricas de validación

| Pos | Sil KMeans ACP | Sil Jer. ACP | CH KMeans ACP | CH Jer. ACP |
|---|---|---|---|---|
| 1 | Scott McKenna | Scott McKenna | Scott McKenna | Scott McKenna |
| 2 | Matthijs de Ligt | Matthijs de Ligt | Matthijs de Ligt | Matthijs de Ligt |
| 3 | César Tárrega | César Tárrega | César Tárrega | César Tárrega |
| 4 | Jean-Charles Castelletto | Jean-Charles Castelletto | Jean-Charles Castelletto | Jean-Charles Castelletto |
| 5 | Harry Maguire | Harry Maguire | Harry Maguire | Harry Maguire |
| 6 | Guillermo Maripán | Guillermo Maripán | Guillermo Maripán | Guillermo Maripán |
| 7 | James Tarkowski | James Tarkowski | James Tarkowski | James Tarkowski |
| 8 | Igor Zubeldia | Igor Zubeldia | Igor Zubeldia | Igor Zubeldia |
| 9 | Charlie Cresswell | Charlie Cresswell | Charlie Cresswell | Charlie Cresswell |
| 10 | Dan Burn | Dan Burn | Dan Burn | Dan Burn |

Transfermarkt es una página web especializada en fichajes y en el valor de mercado de los jugadores de fútbol. Podemos ver su logo en la figura 4.20.

Figura 4.20: Logo Transfermarkt. Extraído de Transfermarkt (2026).

Con el fin de sintetizar los resultados anteriores, se contabilizó la frecuencia con la que cada jugador aparece en los rankings, junto con su año de nacimiento y su valor de mercado estimado (Extraído el 20/04/2026) por Transfermarkt (2026). La Tabla 4.5 recoge los principales candidatos. Antonio Raíllo tiene una valoración de mercado de 1.5 M€ , siendo 4 M€ su valoración más alta según Transfermarkt (2026) (alcanzada el 13/06/2023).

### 4.5.4 Sustitutos condicionados

Con el objetivo de aproximar la lista de candidatos a perfiles realistas desde un punto de vista de planificación deportiva, se aplicaron filtros sobre dos variables fundamentales: edad y minutos disputados. En primer lugar:

Tabla 4.5: Principales jugadores candidatos a sustituto

| Jugador | Año | Posición | Frecuencia | Valor de mercado (M€) |
|---|---|---|---|---|
| Charlie Cresswell | 2002 | DFC | 13 | 25 |
| Guillermo Maripán | 1994 | LD | 13 | 3 |
| James Tarkowski | 1992 | DFC | 13 | 7 |
| Ko Itakura | 1997 | DFC | 13 | 10 |
| Alessio Romagnoli | 1995 | DFC | 9 | 7 |
| Hauke Wahl | 1994 | DFC | 9 | 1.5 |
| Johan Vásquez | 1998 | DFC | 9 | 13 |
| Robin Koch | 1996 | DFC | 9 | 15 |
| César Tárrega | 2002 | DFC | 8 | 12 |
| Dan Burn | 1992 | DFC | 8 | 5 |

- **Edad**: dado que no se buscan sustitutos de mayor edad que Antonio Raíllo, se excluyeron aquellos jugadores cuyo año de nacimiento es anterior a 1991. Posteriormente, se aplicaron restricciones adicionales.

- **Minutos jugados**: para evitar que algunas estadísticas resulten poco representativas por una participación reducida, se impuso un umbral mínimo de 900 minutos disputados durante la temporada, equivalente aproximadamente a diez partidos completos.

Tras aplicar estos criterios iniciales únicamente se eliminaron dos jugadores, por lo que se consideraron restricciones más exigentes sobre la edad.

De acuerdo con Macro Football (2024) (Figura 4.21), el rendimiento de los defensas centrales tiende a disminuir a partir de los 32 años (nacimiento posterior a 1994), mientras que el pico de rendimiento se sitúa aproximadamente en los 27 años (nacimiento posterior a 1998). Estas conclusiones se obtienen a partir del ajuste de modelos suavizados tipo *spline* que relacionan la edad con el impacto escalado del jugador. El máximo de dichas curvas se interpreta como el punto de mayor rendimiento, bajo el supuesto de que, en promedio, los futbolistas alcanzan un único pico a lo largo de su carrera profesional.

En este contexto, el rendimiento pico hace referencia a la edad en la que un jugador alcanza su nivel máximo de contribución media al juego, teniendo en cuenta un conjunto amplio de acciones (defensivas, ofensivas y contextuales) agregadas en una medida de impacto. Este punto no debe interpretarse como un valor puntual aislado, sino como el máximo de una tendencia suavizada que recoge el comportamiento medio del rendimiento en función de la edad, eliminando fluctuaciones debidas a factores circunstanciales (lesiones, minutos disputados, contexto táctico, entre otros).

En consecuencia, se consideraron dos escenarios en el análisis: jugadores nacidos en 1994 o posterior (Tabla 4.6), y jugadores nacidos en 1998 o posterior (Tabla 4.7).

En este último escenario, al restringir de forma notable la población de estudio, aparecen jugadores que no corresponden a perfiles defensivos, especialmente aquellos con frecuencia 1. Esto se explica porque, al trabajar con un conjunto reducido de componentes (primeras variables del ACP), se atenúa el peso relativo de las variables que caracterizan de forma más específica el rendimiento de los defensas centrales, lo que puede favorecer proximidades espurias con jugadores de otras posiciones.

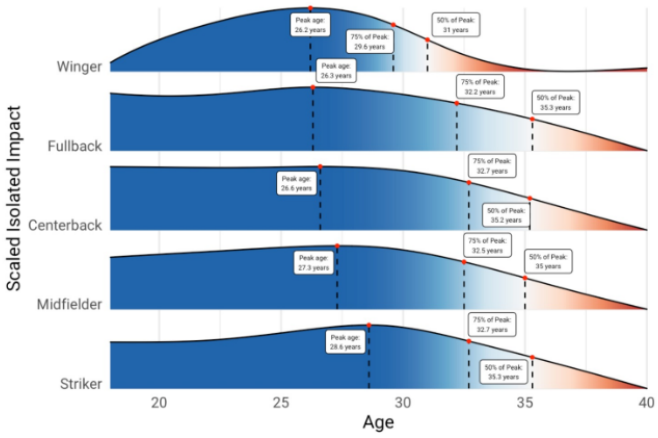


Figura 4.21: Rendimiento por edad por posición. Extraido de Macro Football (2024).

Tabla 4.6: Candidatos a sustituto (nacidos en 1994 o posterior).

| Jugador | Año | Posición | Frecuencia | Valor de mercado (M€) |
|---|---|---|---|---|
| Charlie Cresswell | 2002 | DFC | 13 | 25 |
| Ko Itakura | 1997 | DFC | 13 | 10 |
| Alessio Romagnoli | 1995 | DFC | 9 | 7 |
| Johan Vásquez | 1998 | DFC | 9 | 13 |
| Robin Koch | 1996 | DFC | 9 | 15 |
| César Tárrega | 2002 | DFC | 8 | 12 |
| Jay Idzes | 2000 | DFC | 8 | 10 |
| Jean-Charles Castelletto | 1995 | DFC | 8 | 3.2 |
| Scott McKenna | 1996 | DFC | 8 | 4 |
| Matthijs de Ligt | 1999 | DFC | 6 | 40 |

Tabla 4.7: Candidatos a sustituto de Antonio Raíllo (nacidos en 1998 o posterior).

| Jugador | Año | Posición | Frecuencia | Valor de mercado (M€) |
|---|---|---|---|---|
| Charlie Cresswell | 2002 | DFC | 13 | 25 |
| César Tárrega | 2002 | DFC | 8 | 12 |
| Jay Idzes | 2000 | DFC | 8 | 10 |
| Matthijs de Ligt | 1999 | DFC | 6 | 40 |
| Jaka Bijol | 1999 | DFC | 4 | 18 |
| Saúl Coco | 1999 | LI | 4 | 9 |
| Alex Baena | 2001 | EI | 1 | 45 |
| Kevin Schade | 2001 | EI | 1 | 35 |
| Lorenzo Lucca | 2000 | DC | 1 | 25 |
| Maximilian Beier | 2002 | DC | 1 | 40 |

CAPÍTULO 5

# SIMULACIÓN Y CANDIDATOS ELEGIDOS

En el ámbito profesional, la decisión de incorporar a un jugador no se basa exclusivamente en el análisis de datos, sino que recae en la figura del director deportivo, quien integra información adicional de carácter táctico, contextual y humano (adaptación al vestuario, estilo de juego del equipo, necesidades específicas de la plantilla, entre otros). Dado que este trabajo se centra en un enfoque cuantitativo y no dispone de dichos elementos cualitativos propios de la toma de decisiones en un club profesional, se incorpora una fase de simulación como herramienta complementaria. Aunque esta aproximación no sustituye el criterio experto de un director deportivo, sí proporciona un entorno coherente para comparar alternativas bajo condiciones homogéneas, facilitando así una evaluación más completa de los posibles sustitutos de Antonio Raíllo.

Viendo la tabla 4.7, seleccionaremos a los 3 primeros de dicha Tabla debido a que tienen un número de apariciones similar. Como aspectos a destacar de los jugadores, podemos valorar la altura, la nacionalidad y el equipo actual:

Tabla 5.1: Características físicas y contexto competitivo de los candidatos.

| **Jugador** | **Nacionalidad** | **Altura (cm)** | **Equipo actual** |
|---|---|---|---|
| Charlie Cresswell | ENG | 190 | Toulouse FC |
| César Tárrega | ESP | 194 | Valencia CF |
| Jay Idzes | IDN | 190 | U.S. Sassuolo |

Para elegirlo, hemos usado el videojuego Football Manager 2026 como herramienta de simulación, este es un videojuego de fútbol en el que se disputan las temporadas y se puede ejercer de entrenador. Lo hemos utilizado para intentar prever cuales de nuestros candidatos (Tabla 5.1) sería el indicado para sustituir a Antonio Raíllo en el RCD Mallorca.

En el videojuego, cada jugador tiene unos valores (1-20) de diversas variables físicas, técnicas, mentales y tácticas, así como unas posiciones y unos roles en los que puede

jugar en cada posición. También tiene una valoración de 0.5 a 5 estrellas la cual se compara con el resto del equipo. No es una valoración fija y que se centre únicamente en él, sino en toda la plantilla del club. Además el juego tiene su propio valor de mercado para cada jugador, siendo una aproximación del precio de fichaje en la partida (Figura 5.1).

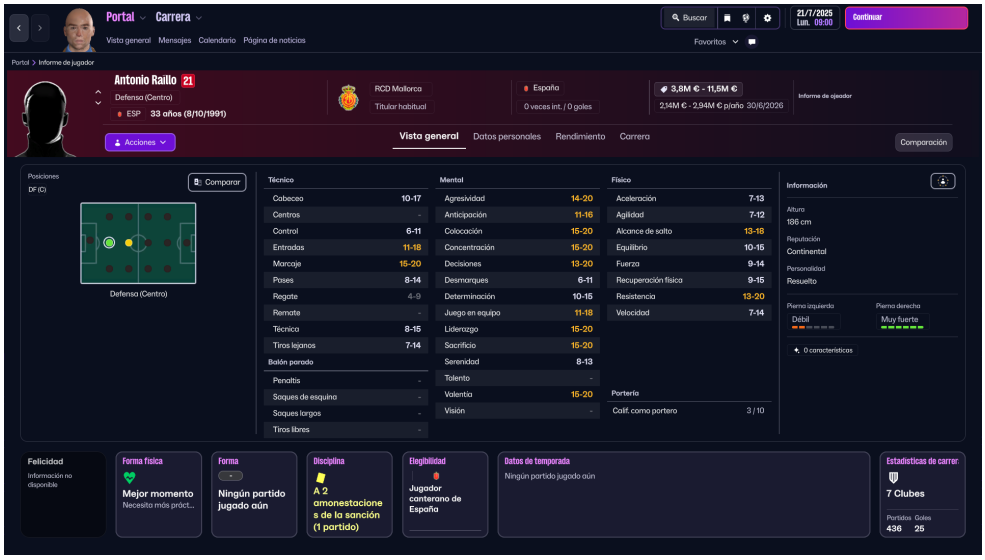


Figura 5.1: Perfil de Antonio Raíllo en el Football Manager 2026, se pueden ver sus estadísticas, sus posibles posiciones, su valor de mercado en el juego.

Se trata de un videojuego de simulación de fútbol ampliamente utilizado, que ofrece un nivel elevado de detalle en la modelización del rendimiento de jugadores y equipos. No obstante, los resultados deben interpretarse como una aproximación, ya que no representan de forma exacta el comportamiento real. La empresa Sports Interactive se encarga del mantenimiento y de la base de datos, la cual es muy completa. Por ejemplo, en Mallorca tenemos el club de fútbol formativo San Francisco (Figura 5.2), el cual no tiene primer equipo, y cuando entras a la página del RCD Mallorca, entre los equipos afiliados aparece este club debido a su unión en la categoría Juvenil División de Honor, la cual tiene una limitación de un máximo de 1 equipo por club, por tanto el Mallorca y el San Francisco se aliaron para que los jugadores del Mallorca que no tengan sitio en el Juvenil División de Honor del RCD Mallorca puedan jugar en el San Francisco.

Es por esto, que el videojuego se utiliza en varios aspectos del fútbol profesional. Tiene una gran base de datos y bastante fiel a la vida real, por tanto hay equipos que buscan jugadores a través de esta base de datos, por ejemplo, Roberto Firmino, exjugador del Liverpool FC y campeón de la Champions League, llego al Hoffeinheim gracias al Football Manager, Lutz Pfannenstiel (ojeador del equipo) confesó haber conocido al jugador a través del videojuego, y a partir de ahí empezó a seguirle y se decidió a ficharlo por 4M de euros cuando solo tenía 18 años, varias temporadas más tarde lo vendieron por 41M de euros al Liverpool. (As.com 2016)

Otros ejemplos de uso del simulador en la vida real pueden ser los casos de Will Still, entrenador francés nacido en 1992. Su primer trabajo como entrenador principal fue en el Stade Reims cuando aún no disponía del título de entrenador necesario para hacerlo. El mismo admite que el videojuego fue lo que le impulsó y le ayudó a llegar a

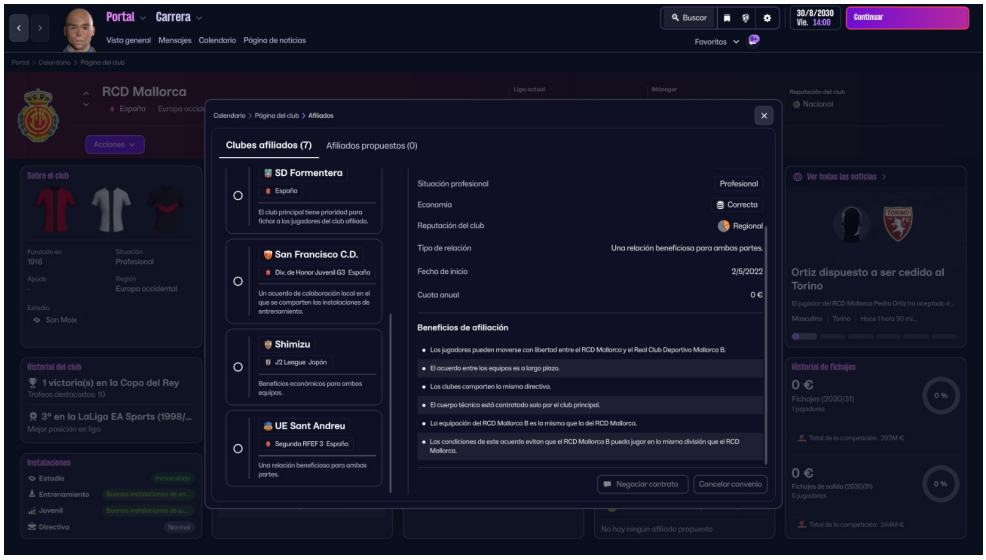


Figura 5.2: Equipos afiliados al RCD Mallorca, entre los cuales aparece el San Francisco, club formativo de la isla.

ser entrenador de fútbol (Meristation 2023).

Para ver cual es el candidato ideal hemos seguido el siguiente procedimiento:

- **Modificación de la base de datos:** Con la compra del juego, te viene incluido un programa llamado *Football Manager Pre-Game Editor*, con esto se puede modificar la totalidad de la base de datos (mover jugadores de equipo, cambiar presupuestos, aumentar estadísticas de jugadores,...). Con esta herramienta, pudimos eliminar a Marash Kumbulla de la plantilla del RCD Mallorca (jugador cedido con opción de compra no obligatoria como posible reemplazo de Antonio Raíllo) y añadir nuestro candidato a sustituto.

- **Simulación:** Para iniciar la partida, se selecciona que cargue la información de las 5 grandes ligas (solo las primeras divisiones) y se selecciona la opción de iniciar en el paro para evitar influir en las decisiones de la partida. Se simula un total de 6 temporadas en cada partida, y se realizan 5 partidas con cada sustituto.

- **Recogida de datos:** Al finalizar la simulación, se puede acceder al historial de cada jugador para conocer el número de partidos jugados en cada temporada, la nota media de los partidos y se puede acceder al historial de las competiciones cargadas para conocer la clasificación de cada temporada, estos datos se recogieron en un *DataFrame* en RStudio para realizar los gráficos.

Con este trabajo realizado, tenemos los datos recogidos en las tablas 5.2, 5.3 y 5.4.

Veamos los gráficos de estos datos, primero tenemos la nota media de cada temporada de todas las simulaciones, que son 5 por cada jugador y 6 temporadas por simulación. La nota media la calcula Football Manager en función del rendimiento durante el partido, al inicio de este todos los jugadores inician con un 6.0, y en función de sus acciones va sumando o bajando la valoración, en función de la posición del

Tabla 5.2: Valoraciones obtenidas en las simulaciones de Football Manager.

| | 2025-26 | 2026-27 | 2027-28 | 2028-29 | 2029-30 | 2030-31 | Escala | Temporada de retiro de Raíllo |
|---|---|---|---|---|---|---|---|---|
| **Charlie Cresswell 1** | 5,9 | 0 | 0 | 0 | 0 | 0 | **0-10** | 2028-29 |
| **Charlie Cresswell 2** | 6,65 | 6,62 | 6,4 | 0 | 0 | 0 | **0-10** | 2028-29 |
| **Charlie Cresswell 3** | 6,64 | 6,75 | 6,45 | 0 | 0 | 0 | **0-10** | 2028-29 |
| **Charlie Cresswell 4** | 6,55 | 6,76 | 6,81 | 0 | 0 | 0 | **0-10** | 2028-29 |
| **Charlie Cresswell 5** | 6,76 | 6,96 | 6,68 | 0 | 0 | 0 | **0-10** | 2028-29 |
| **César Tárrega 1** | 6,85 | 6,93 | 6,77 | 6,91 | 6,93 | 6,95 | **0-10** | 2028-29 |
| **César Tárrega 2** | 6,96 | 6,93 | 7,07 | 7,12 | 6,97 | 7,33 | **0-10** | 2028-29 |
| **César Tárrega 3** | 6,87 | 6,99 | 6,75 | 7,03 | 6,89 | 6,98 | **0-10** | 2027-28 |
| **César Tárrega 4** | 6,92 | 6,86 | 6,87 | 6,85 | 7,1 | 6,9 | **0-10** | 2027-28 |
| **César Tárrega 5** | 6,98 | 6,97 | 6,97 | 7 | 7,02 | 7,02 | **0-10** | 2027-28 |
| **Jay Idzes 1** | 6,8 | 0 | 0 | 0 | 0 | 0 | **0-10** | 2027-28 |
| **Jay Idzes 2** | 6,78 | 6,58 | 6,93 | 7,13 | 6,67 | 0 | **0-10** | 2028-29 |
| **Jay Idzes 3** | 6,38 | 0 | 6,9 | 6,77 | 6,83 | 6,79 | **0-10** | 2028-29 |
| **Jay Idzes 4** | 0 | 6,75 | 0 | 0 | 0 | 0 | **0-10** | 2027-28 |
| **Jay Idzes 5** | 6,8 | 7 | 0 | 0 | 0 | 0 | **0-10** | 2028-29 |

Tabla 5.3: Minutos disputados en las simulaciones de Football Manager.

| | 2025-26 | 2026-27 | 2027-28 | 2028-29 | 2029-30 | 2030-31 | Escala |
|---|---|---|---|---|---|---|---|
| **Charlie Cresswell 1** | 1 | 0 | 0 | 0 | 0 | 0 | **0-38** |
| **Charlie Cresswell 2** | 2 | 12 | 2 | 0 | 0 | 0 | **0-42** |
| **Charlie Cresswell 3** | 8 | 4 | 4 | 0 | 0 | 0 | **0-38** |
| **Charlie Cresswell 4** | 15 | 20 | 17 | 0 | 0 | 0 | **0-38** |
| **Charlie Cresswell 5** | 8 | 14 | 13 | 0 | 0 | 0 | **0-38** |
| **César Tárrega 1** | 7 | 23 | 15 | 23 | 35 | 27 | **0-38** |
| **César Tárrega 2** | 23 | 22 | 37 | 31 | 37 | 41 | **0-42** |
| **César Tárrega 3** | 21 | 15 | 36 | 32 | 36 | 32 | **0-38** |
| **César Tárrega 4** | 19 | 35 | 32 | 33 | 37 | 36 | **0-38** |
| **César Tárrega 5** | 22 | 35 | 35 | 34 | 34 | 35 | **0-38** |
| **Jay Idzes 1** | 1 | 0 | 0 | 0 | 0 | 0 | **0-38** |
| **Jay Idzes 2** | 13 | 13 | 12 | 3 | 15 | 0 | **0-38** |
| **Jay Idzes 3** | 7 | 1 | 9 | 17 | 32 | 21 | **0-38** |
| **Jay Idzes 4** | 0 | 4 | 0 | 0 | 0 | 0 | **0-38** |
| **Jay Idzes 5** | 7 | 1 | 0 | 0 | 0 | 0 | **0-38** |

jugador suman más según que acciones, por ejemplo, para los defensas sumará más un despeje que a un delantero.

En la Figura 5.3 se puede observar que el jugador con una media más alta en general es César Tárrega, siendo además el único jugador que se mantiene en el club en todas las temporadas de todas las simulaciones.

En cuanto a los partidos jugados, todas las temporadas realizadas en LaLiga EA Sports (Primera División) tienen un total de 38 partidos, mientras que las realizadas en LaLiga Hypermotion (Segunda División) tienen un total de 42 partidos debido a que en Segunda División participan 22 equipos, frente a los 20 de Primera División. En este gráfico se ve muy claro que el jugador que más partidos ha jugado en la mayoría de temporadas ha sido también César Tárrega.

Y veamos también la posición del Mallorca en cada una de las temporadas, el rango de estos valores es de 1 a 20, cuando está por debajo de estos significa que el club ha jugado esa temporada en Segunda División. En este caso las mejores posiciones no se han conseguido con César Tárrega sino en las partidas con Charlie Cresswell y Jay Idzes, consiguiendo 2 clasificaciones a competiciones europeas con cada jugador (mientras

Tabla 5.4: Posición final del RCD Mallorca en LaLiga en cada simulación realizada en Football Manager 2026. (*Descenso), (** En 2ª División), (*** Clasificación a competición europea), Escala: 0-20.

| | 2025-26 | 2026-27 | 2027-28 | 2028-29 | 2029-30 | 2030-31 |
|---|---|---|---|---|---|---|
| **Charlie Cresswell 1** | 8 | 12 | 13 | 8 | 11 | 14 |
| **Charlie Cresswell 2** | 10 | 6*** | 6*** | 12 | 18* | ** |
| **Charlie Cresswell 3** | 16 | 7 | 15 | 11 | 14 | 14 |
| **Charlie Cresswell 4** | 13 | 15 | 10 | 7*** | 14 | 16 |
| **Charlie Cresswell 5** | 12 | 14 | 19* | ** | ** | ** |
| **César Tárrega 1** | 15 | 9 | 12 | 17 | 14 | 9 |
| **César Tárrega 2** | 12 | 12 | 11 | 8 | 18* | ** |
| **César Tárrega 3** | 10 | 16 | 15 | 12 | 15 | 10 |
| **César Tárrega 4** | 7 | 12 | 12 | 16 | 10 | 13 |
| **César Tárrega 5** | 12 | 10 | 13 | 12 | 8 | 19* |
| **Jay Idzes 1** | 18* | ** | ** | 14 | 19* | ** |
| **Jay Idzes 2** | 11 | 11 | 10 | 12 | 17 | 18* |
| **Jay Idzes 3** | 15 | 10 | 6*** | 12 | 7 | 20* |
| **Jay Idzes 4** | 8 | 6*** | 11 | 12 | 15 | 18* |
| **Jay Idzes 5** | 12 | 4*** | 6*** | 10 | 9 | 13 |

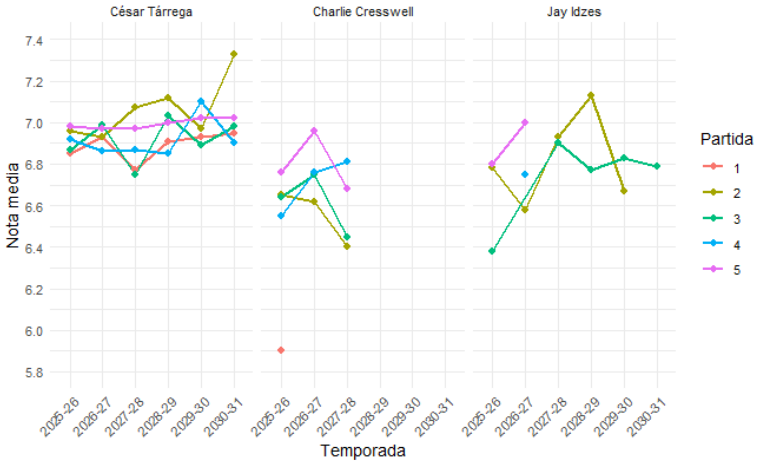


Figura 5.3: Nota media de todos los partidos jugados por temporada en cada simulación. La valoración en el Football Manager suele interpretarse de la siguiente manera: <6.0 → Mal partido, 6.0–6.6 → Rendimiento normal, 6.7–7.4 → Buen partido, 7.5–8.4 → Muy buen partido, >8.5 → Actuación sobresaliente. Fuente: Elaboración propia.

estaba en el equipo), pero no siempre con él en el equipo, asimismo, con César Tárrega se ve que el club se estabiliza en Primera División, descendiendo 2 veces en todas las simulaciones, en las de Jay Idzes hay 4 descensos y en las de Charlie Cresswell hay 2.

Ahora comparemos datos entre ellos, en este gráfico veremos la relación de la posición en la tabla de RCD Mallorca con la cantidad de partidos jugados por el jugador, cuanto más arriba a la derecha significa que el Mallorca quedó en una posición alta en la tabla con el jugador disputando varios partidos.

Se observa que el jugador que acumula más puntos arriba a la derecha es César

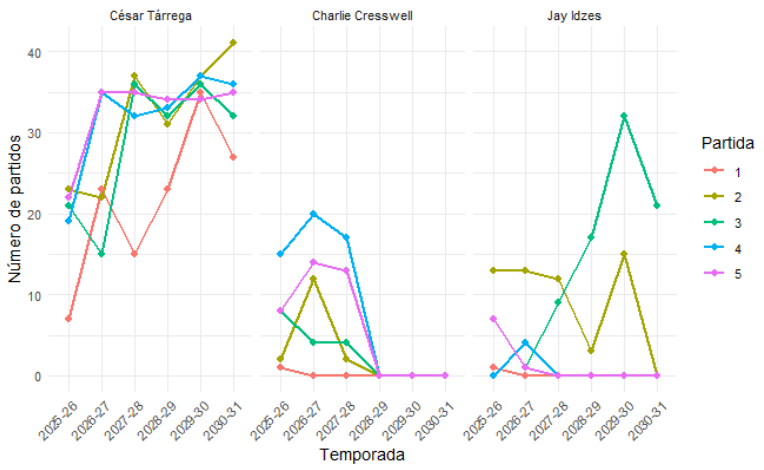


Figura 5.4: Número de partidos jugados por temporada en cada simulación. Fuente: Elaboración propia.

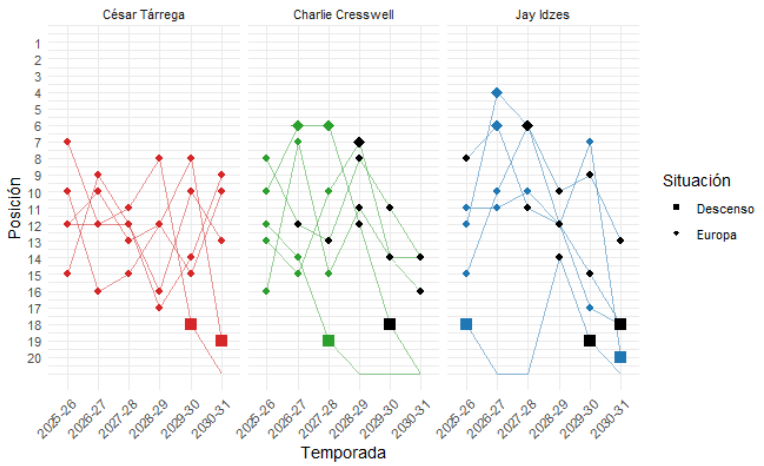


Figura 5.5: Posición RCD Mallorca por temporada en cada simulación. El color negro en las figuras indica que el jugador jugó 0 partidos en esa temporada. Fuente: Elaboración propia.

Tárrega, pero el jugador que tiene un punto más alto es Jay Idzes pero está muy a la izquierda. Este gráfico refuerza la idea de que el jugador que más partidos ha jugado es César Tárrega y que en sus partidas el Mallorca se ha consolidado en Primera División la mayoría de las temporadas.

Ahora se compara la nota media de la temporada con la posición final en la tabla, de nuevo cuanto más arriba a la derecha significa una mejor valoración media con una mayor posición en la tabla.

Se ve, de nuevo, que César Tárrega es el jugador que se posiciona más a la derecha en su mayoría, mientras que la partida con la posición más alta es con Jay Idzes.

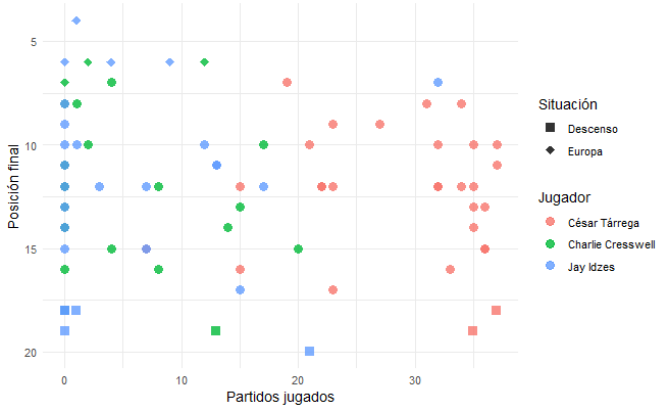


Figura 5.6: Relación entre posición del RCD Mallorca y la cantidad de partidos jugados por el jugador. Fuente: Elaboración propia.

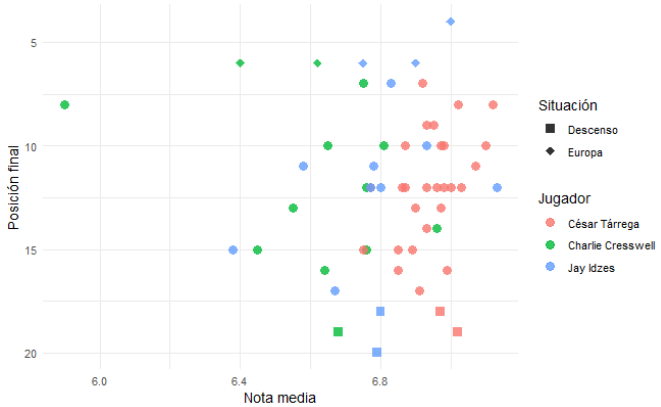


Figura 5.7: Relación entre la posición del RCD Mallorca en la tabla y la valoración media de la temporada. Fuente: Elaboración propia.

## 5.1 Elección de sustituto

Con estos datos y en base a estas simulaciones, se podría concluir que el sustituto elegido sería César Tárrega, si bien es cierto que no se han conseguido grandes posiciones en la tabla, se observa que es el jugador más regular y con mayor valoración en la mayoría de partidas. Destaca el hecho de que es el único jugador que no ha sido vendido en ninguna de las temporadas, haciéndose con un puesto en el equipo como titular y convirtiéndose en un líder del equipo según las dinámicas de plantilla del simulador.

Con esto no podemos asegurar que César Tárrega sería un buen sustituto de Antonio Raíllo, pero se prevé que al menos será un jugador influyente en el Mallorca con el paso de los años.

CAPÍTULO 6

# DISCUSIÓN Y CONCLUSIONES

El presente trabajo muestra cómo traducir el problema futbolístico de sustituir a un DFC en un problema geométrico de proximidad en $\mathbb{R}^p$. Las técnicas de clustering, combinadas con el Análisis de Componentes Principales (ACP), permiten explorar el entorno de $\mathbf{x}_r$ y detectar candidatos robustos a partir de múltiples configuraciones y criterios de validación. La convergencia de determinados nombres en distintos escenarios refuerza la idea de que existen perfiles con una similitud estable respecto al jugador de referencia, lo que aporta solidez a los resultados obtenidos. Esta evidencia puede integrarse con información externa a los datos analizados (como aspectos contractuales, contexto táctico o disponibilidad) con el fin de apoyar una toma de decisiones más informada en el ámbito deportivo.

No obstante, el trabajo presenta algunas limitaciones. La elección de la distancia euclídea, la alta dimensionalidad de los datos y la posible multicolinealidad entre variables justifican el uso del ACP, pero al mismo tiempo sugieren la conveniencia de explorar métricas alternativas en futuras investigaciones, como la distancia del coseno o la distancia de Gower en presencia de variables mixtas. Asimismo, el análisis se ha restringido a una única temporada y a las cinco grandes ligas europeas, lo que puede limitar la generalización de los resultados y abre la puerta a futuras ampliaciones del estudio.

Adicionalmente, la fase de simulación incorporada mediante *Football Manager 2026* debe interpretarse con cautela. Aunque proporciona un entorno controlado que permite comparar el rendimiento potencial de los candidatos en condiciones homogéneas, se trata de una representación simplificada de la realidad, basada en modelos internos y parámetros propios del videojuego. En consecuencia, los resultados obtenidos pueden verse condicionados por supuestos que no reflejan completamente la complejidad del fútbol profesional, como factores psicológicos, dinámicas de vestuario o decisiones tácticas específicas del entrenador. Por ello, la simulación no sustituye el criterio experto en la toma de decisiones, sino que actúa como una herramienta complementaria que permite enriquecer el análisis realizado.

## 6.1 Líneas futuras

Entre las posibles líneas futuras de este TFG se encuentra la ampliación de la base de datos, incorporando un mayor número de jugadores procedentes de ligas inferiores. Esto permitiría identificar perfiles con menor valor de mercado pero con un elevado potencial de desarrollo. No obstante, sería necesario introducir algún mecanismo de ajuste que tenga en cuenta el nivel competitivo de cada liga, de forma análoga a sistemas como el utilizado en la clasificación de la Bota de Oro, donde el valor de los goles depende de la liga en la que se consiguen.

Asimismo, se podrían incorporar nuevas variables relevantes, como la pierna dominante o la altura del jugador, cuya importancia varía en función de la posición específica en el campo. Del mismo modo, los clubes profesionales disponen de informes cualitativos sobre los jugadores (aspectos personales, capacidad de adaptación, etc.), que podrían integrarse en el análisis para mejorar la selección final de candidatos, favoreciendo una mejor adaptación al contexto del club (Marca 2025a).

Otra posibilidad consiste en la incorporación de modelos predictivos que permitan no solo identificar jugadores con características similares, sino también estimar su rendimiento futuro. En este sentido, podrían emplearse técnicas de aprendizaje supervisado que, a partir de datos históricos, modelicen la evolución del rendimiento de los jugadores en función de variables como la edad, la posición o el contexto competitivo. Este enfoque permitiría anticipar el desarrollo potencial de cada candidato y reducir la incertidumbre asociada a la toma de decisiones en fichajes, complementando así el análisis basado en similitud estática utilizado en este trabajo.

### Declaración sobre el uso de inteligencia artificial

En la elaboración del presente trabajo se han empleado herramientas basadas en inteligencia artificial como apoyo en tareas auxiliares. En concreto, se han utilizado para la mejora de la redacción y reformulación de textos con el fin de aumentar la claridad y cohesión del documento, así como en la generación y depuración de código orientado a la obtención de datos mediante técnicas de *web scraping* y a la construcción de gráficos en el entorno `R`.

El uso de estas herramientas se ha limitado a funciones de apoyo técnico y no ha sustituido en ningún caso el proceso de análisis, la interpretación de los resultados ni la elaboración de las conclusiones, que han sido realizadas íntegramente por el autor. Asimismo, se ha revisado y validado todo el contenido generado para garantizar su adecuación académica y su coherencia con los objetivos del trabajo.

### Repositorio de código

El código utilizado para la extracción, el procesamiento de datos y la generación de resultados está disponible en el siguiente repositorio:

`https://github.com/joanmiquelr/Football-Data`

El repositorio incluye el procesamiento en `R` y la generación de gráficos empleados en este trabajo.

# Bibliografía


Akhanlı, Serhat Emre y Christian Hennig (2022). «Clustering of football players based on performance data and aggregated clustering validity indexes». En: *arXiv preprint arXiv:2204.09793*.

As.com (nov. de 2016). *El Hoffenheim descubrió a Firmino en el Football Manager*. Actualizado a 17 de noviembre de 2016 (CET). URL: https://as.com/futbol/2016/11/16/internacional/1479332249_844251.html (visitado 02-03-2026).

Baumer, B. S., D. T. Kaplan y N. J. Horton (2015). *Modern Data Science with R*. CRC Press.

Bunker, R. y F. Thabtah (2019). «A machine learning framework for sport result prediction». En: *Applied Computing and Informatics* 15.1, págs. 27-33.

Cervone, D. et al. (2016). «A multiresolution stochastic process model for predicting basketball possession outcomes». En: *Journal of the American Statistical Association* 111.514, págs. 585-599.

Consejo Superior de Deportes (2025). *Histórico de licencias deportivas federadas. Actualizado 2024*. URL: https://www.csd.gob.es/sites/default/files/media/files/2025-07/Hist%C3%B3rico%20licencias%20%28actualizado%202024%29.pdf (visitado 02-03-2026).

Das, Nayan Ranjan et al. (2023). «An intelligent clustering framework for substitute recommendation and player selection». En: *The Journal of Supercomputing* 79, págs. 16409-16441. DOI: 10.1007/s11227-023-05314-2.

Decroos, T. et al. (2019). «Actions speak louder than goals: Valuing player actions in soccer». En: *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, págs. 1851-1861.

Everitt, Brian S. et al. (2011). *Cluster Analysis*. 5.ª ed. Wiley Series in Probability and Statistics. Chichester, UK: John Wiley & Sons. ISBN: 978-0-470-97844-3.

Fisher, Lloyd y John W. Van Ness (1971). «Admissible clustering procedures». En: *Biometrika* 58, págs. 91-104. DOI: 10.1093/biomet/58.1.91.

Gower, John C. (jul. de 1990). «Clustering axioms». En: *Classification Society of North America Newsletter*, págs. 2-3.

Gu, Linda et al. (2025). «Playing style identification in team sports: A systematic review from statistical dimensionality reduction to unsupervised machine learning». En: *International Journal of Sports Science & Coaching*. OnlineFirst, September 2025.

Hartigan, John A. (1975). *Clustering Algorithms*. New York: John Wiley & Sons.

Hartigan, John A. y Manchek A. Wong (1979). «Algorithm AS 136: A K-Means Clustering Algorithm». En: *Applied Statistics* 28.1, págs. 100-108. DOI: 10.2307/2346830.

Hastie, Trevor, Robert Tibshirani y Jerome Friedman (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. 2nd. Springer Series in Statistics. New York: Springer. DOI: 10.1007/978-0-387-84858-7.

Hubert, Lawrence J. y Phipps Arabie (1985). «Comparing Partitions». En: *Journal of Classification* 2, págs. 193-218.

Kaufman, Leonard y Peter J. Rousseeuw (1990). *Finding Groups in Data. An Introduction to Cluster Analysis*. New York: John Wiley & Sons.

Lance, G. N. y W. T. Williams (1967). «A General Theory of Classificatory Sorting Strategies: 1. Hierarchical Systems». En: *The Computer Journal* 9.4, págs. 373-380. DOI: 10.1093/comjnl/9.4.373.

Lemmer, H. H. (2013). «The value of statistical analysis in cricket performance evaluation». En: *South African Journal for Research in Sport, Physical Education and Recreation* 35.3, págs. 113-126.

MacNaughton-Smith, Peter et al. (1964). «Dissimilarity analysis». En: *Nature* 202, págs. 1034-1035. DOI: 10.1038/2021034a0.

Macro Football (2024). *Aging curves in football*. URL: https://macro-football.com/other/aging/.

Marca (oct. de 2025a). *El método Fajardo: así trabaja la dirección deportiva del Betis*. URL: https://www.marca.com/futbol/betis/2025/10/14/metodo-fajardo-asi-trabaja-direccion-deportiva-betis.html (visitado 02-03-2026).

— (sep. de 2025b). *El Rayo pudo inscribir solo 21 jugadores en Conference y canteranos del primer equipo*. URL: https://www.marca.com/futbol/rayo/2025/09/29/rayo-pudo-inscribir-21-jugadores-conference-canteranos-primer-equipo.html (visitado 02-03-2026).

Meristation (2023). *Cómo el Football Manager convirtió a Will Still en un entrenador de élite sin licencia*. URL: https://as.com/meristation/noticias/como-el-football-manager-convirtio-a-will-still-en-un-entrenador-elite-sin-licencia-n/ (visitado 02-03-2026).

Miller, A., L. Bornn y R. Adams (2014). «Factorized point process intensities: A spatial analysis of professional basketball». En: *International Conference on Machine Learning (ICML)*, págs. 235-243.

Mirkin, Boris (1996). *Mathematical Classification and Clustering*. Dordrecht: Kluwer Academic Publishers.

Morgan, Byron J. T. y A. P. G. Ray (1995). «Non-uniqueness and inversions in cluster analysis». En: *Applied Statistics* 44, págs. 117-143. DOI: 10.2307/2986198.

Murtagh, Fionn (1985). *Multidimensional Clustering Algorithms*. Vol. 4. COMPSTAT Lectures. Vienna: Physica-Verlag.

Piccarreta, Raffaella y Francesco C. Billari (2007). «Clustering work and family trajectories by using a divisive algorithm». En: *Journal of the Royal Statistical Society: Series A (Statistics in Society)* 170, págs. 1061-1078. DOI: 10.1111/j.1467-985X.2007.00483.x.

Rand, William M. (1971). «Objective Criteria for the Evaluation of Clustering Methods». En: *Journal of the American Statistical Association* 66.336, págs. 846-850.

Revista Líbero (2024). *Fútbol, un deporte que une al mundo*. URL: https://revistalibero.com/blogs/contenidos/futbol-un-deporte-que-une-al-mundo (visitado 02-03-2026).

Rousseeuw, Peter J. (1987). «Silhouettes: A Graphical Aid to the Interpretation and Validation of Cluster Analysis». En: *Journal of Computational and Applied Mathematics* 20, págs. 53-65. DOI: 10.1016/0377-0427(87)90125-7.

Tibshirani, Robert, Guenther Walther y Trevor Hastie (2001). «Estimating the Number of Clusters in a Data Set Via the Gap Statistic». En: *Journal of the Royal Statistical Society: Series B (Statistical Methodology)* 63.2, págs. 411-423. DOI: 10.1111/1467-9868.00293.

Transfermarkt (2026). *Transfermarkt España: valores de mercado, fichajes y estadísticas de fútbol.* URL: https://www.transfermarkt.es.